

**Modelagem Matemática da Rede de
Transporte Público de São Paulo**
*Uma análise da Rede de Ônibus Operada
pela SPTrans*

Francielly Cristina Pogogelski Meira

UNIVERSIDADE DE SÃO PAULO
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA
DEPARTAMENTO DE MATEMÁTICA APLICADA

Programa: Matemática Aplicada
Orientadora: Prof.^a Dr.^a Daielly Melina Nassif Mantovani

**Modelagem Matemática da Rede de
Transporte Público de São Paulo**
*Uma análise da Rede de Ônibus Operada
pela SPTrans*

Francielly Cristina Pogogelski Meira

Monografia apresentada ao Departamento
de Matemática Aplicada do Instituto
de Matemática e Estatística, da
Universidade de São Paulo, como parte
dos requisitos para obter o título de
Bacharel em Matemática Aplicada.

Autorizo a reprodução e divulgação total ou parcial deste trabalho, por qualquer meio convencional ou eletrônico, para fins de estudo e pesquisa, desde que citada a fonte.

Agradecimentos

March comes in like a lion, and goes out like a lamb.

Agradeço profundamente ao meu pai, que desde cedo me ensinou o valor do estudo e do conhecimento, e a minha mãe, por todo o apoio incondicional.

Resumo

Francielly Cristina Pogogelski Meira. **Modelagem Matemática da Rede de Transporte Público de São Paulo: Uma análise da Rede de Ônibus Operada pela SPTrans.**
Dissertação (Bacharelado). Instituto de Matemática e Estatística, Universidade de São Paulo, São Paulo.

A cidade de São Paulo enfrenta diariamente desafios complexos de mobilidade urbana, com milhões de pessoas dependentes do transporte coletivo. Este trabalho tem como objetivo avaliar a eficiência da rede municipal de ônibus operada pela SPTrans e identificar potenciais pontos de melhoria em sua estrutura, por meio da modelagem matemática de redes. Utilizando dados do GTFS (General Transit Feed Specification) e séries temporais de passageiros transportados entre 2015 e 2025, incluindo o período da pandemia de Covid-19, foi realizada a integração entre informações espaciais das rotas e dados demográficos do Censo 2022 do IBGE, considerando também as subdivisões territoriais da cidade. A metodologia adotada combina técnicas de análise estatística e de redes, com a criação de grafos por meio da biblioteca NetworkX, permitindo avaliar métricas de centralidade e cobertura territorial da malha de transporte coletivo. Dentre os principais resultados, destacam-se a percepção das reestruturações do sistema após 2018, com quedas nas métricas de centralidade, indicando uma rede menos concentrada e mais distribuída, com menor dependência de poucos nós críticos, e a observação da reestruturação das rotas da Zona Oeste após inauguração da Estação Vila Sônia, em 2022, trazendo ganhos de tempo, mas também desafios de custo para os passageiros. Quanto às zonas da cidade, observamos uma maior quantidade de rotas e paradas na zona Leste e Sul, com alta demanda populacional e intenso uso das linhas de ônibus, e um planejamento mais intenso do transporte nas zonas Oeste e Centro, liderando em quantidade de rotas novas. Em relação ao perfil dos passageiros, observou-se uma redução do pagamento em dinheiro, aumento no uso de gratuidades e recuperação gradual da demanda após uma queda abrupta em 2020, ainda não atingindo os níveis pré-pandemia. Em relação à eficiência, identificamos melhorias, com avanços sociais e tecnológicos, e pontos de atenção em regiões superpopuladas e que tiveram um aumento no custo do transporte. Por fim, foi desenvolvido um painel interativo para visualização pública dos resultados, promovendo transparência e apoio ao planejamento baseado em evidências. Os resultados contribuem para uma compreensão mais aprofundada da estrutura e eficiência do transporte público paulistano, oferecendo subsídios para o planejamento urbano e a formulação de políticas de mobilidade mais equilibradas e inclusivas.

Palavras-chave: grafos. transporte público. ônibus. São Paulo. GTFS. mobilidade urbana. eficiência.

Abstract

Francielly Cristina Pogogelski Meira. **Mathematical Modeling of the Public Transportation Network of São Paulo: *An Analysis of the Bus Network Operated by SPTrans***. Thesis (Bachelor). Institute of Mathematics and Statistics, University of São Paulo, São Paulo.

The city of São Paulo faces complex urban mobility challenges on a daily basis, with millions of people relying on public transportation. This study aims to assess the efficiency of the municipal bus network operated by SPTrans and to identify potential areas for improvement in its structure through mathematical network modeling. Using GTFS (General Transit Feed Specification) data and time series of transported passengers from 2015 to 2025, including the period of the Covid-19 pandemic, spatial information on routes was integrated with demographic data from the 2022 IBGE Census, also taking into account the city's territorial subdivisions. The adopted methodology combines statistical and network analysis techniques, with the creation of graphs using the NetworkX library, allowing the evaluation of centrality metrics and territorial coverage of the public transport network. Among the main results, the study highlights the system's restructurings after 2018, with declines in centrality metrics indicating a less concentrated and more distributed network, with reduced dependence on a few critical nodes, as well as the restructuring of routes in the Western Zone following the opening of Vila Sônia Station in 2022, which brought time savings but also cost challenges for passengers. Regarding the city's regions, a greater number of routes and stops were observed in the Eastern and Southern Zones, where population density and bus usage are high, while transport planning efforts were more intense in the Western and Central Zones, which led in the creation of new routes. Concerning passenger profiles, a decrease in cash payments, an increase in the use of free passes, and a gradual recovery in demand were observed after a sharp decline in 2020, still not reaching pre-pandemic levels. In terms of efficiency, improvements were identified, with social and technological advances, alongside points of concern in overpopulated areas that experienced an increase in transportation costs. Finally, an interactive dashboard was developed for public visualization of the results, promoting transparency and supporting evidence-based planning. The findings contribute to a deeper understanding of the structure and efficiency of São Paulo's public transportation system, providing insights for urban planning and the development of more balanced and inclusive mobility policies.

Keywords: graphs. public transportation. buses. São Paulo. GTFS. urban mobility. efficiency.

Sumário

Introdução	1
1 Metodologia	5
1.1 O General Transit Feed Specification (GTFS)	5
1.2 Dados de passageiros por linha	6
1.2.1 Padronização e otimização	7
1.2.2 Unificação	8
1.3 Dados complementares	8
1.3.1 Dados do IBGE	8
1.3.2 Estações de trem e metrô	10
1.3.3 Zonas da cidade de São Paulo	10
1.4 Exploração inicial dos dados: busca por inconsistências	10
1.4.1 Rotas descontinuadas, sem dados ou com dados faltantes: Análise de intersecção	11
1.5 Solicitação de dados ao Serviço de Informação ao Cidadão	13
1.5.1 Análise das inconsistências	14
1.6 Descrição da estrutura final dos dados	15
1.6.1 Rotas	15
1.6.2 Paradas	15
1.6.3 Passageiros	15
1.6.4 População	16
1.6.5 Estações de trem e metrô	16
1.6.6 Merges	16
1.7 Grafos	17
1.7.1 Definição	17
1.7.2 Aplicação	18
1.8 Cálculo da distância percorrida pelas rotas	20
1.9 Noções estatísticas	21

1.9.1	Regressão linear	21
1.9.2	O boxplot	21
2	Resultados	23
2.1	Estatísticas e análises gráficas	23
2.1.1	Quantidade de linhas e paradas ao longo do tempo	23
2.1.2	Novas linhas e paradas ao longo do tempo	30
2.1.3	Correlação com a população	35
2.1.4	Análise geral das rotas	36
2.1.5	Ranking de rotas	43
2.1.6	Análise de centralidade	44
2.1.7	Análise geral dos passageiros	47
2.2	Análise da Reestruturação das Linhas de Ônibus da Zona Oeste após a Inauguração da Estação Vila Sônia	50
2.2.1	Contexto da Inauguração	50
2.2.2	Seleção das Linhas da Zona Oeste	50
2.2.3	Histórico de passageiros nas linhas afetadas	51
2.2.4	As duas linhas mais afetadas: 745810 e 701310	52
2.3	Painel interativo - Analise qualquer rota da cidade da SPTrans	56
2.4	Resumo dos principais resultados e suas interpretações	58
3	Conclusões	61
	Referências	63

Introdução

A Região Metropolitana de São Paulo possui cerca de 20,5 milhões de habitantes, sendo 11 milhões apenas da cidade de São Paulo. Toda essa população enfrenta, diariamente, o estresse do transporte, seja ele coletivo ou individual, gastando, em média, 2h47 por dia ao optar pelo transporte coletivo, em sua maioria, ônibus (REDE NOSSA SÃO PAULO, 2024).

A SPTrans, empresa responsável pelo transporte municipal de São Paulo, disponibiliza na web dados sobre as linhas e quantidade de passageiros transportados. De acordo com o Relatório Integrado de Administração da Empresa de 2024, foram transportados, em média, 7,13 milhões de passageiros por dia útil, através de 1.320 linhas, cobrindo 4,7 mil km, com uma frota de 13.277 veículos (SPTRANS - SÃO PAULO TRANSPORTE S.A., 2024). O sistema de transporte que a empresa fornece, porém, está longe de atender à crescente demanda da população.

Atento à problemática do transporte paulista, YAI (2016) propõe uma análise da qualidade e confiabilidade dos dados GTFS (General Transit Feed Specification) disponibilizados pela SPTrans. Utilizando ferramentas como Node.js e MongoDB, seu trabalho identifica falhas, inconsistências e características operacionais peculiares no sistema de ônibus da cidade, como variações de frequência, duplicidade de paradas e velocidades inconsistentes. A partir disso, valida o uso dos dados para análises críticas sobre a operação e o planejamento da rede, além de propor métricas para avaliação da qualidade do serviço, concluindo que, apesar de possuir algumas inconsistências, os dados disponibilizados pela SPTrans podem ser usados para estudos aprofundados do transporte público operado pela empresa na cidade, seguindo a recomendação de estruturação de dados do GTFS. No entanto, o estudo mantém o foco em análises baseadas em registros operacionais e não se debruça sobre a estrutura territorial do sistema ou sobre sua cobertura em relação à população.

Por outro lado, SOUSA (2016) avalia a robustez da rede de transporte público da cidade de São Paulo por meio da modelagem da rede como um grafo complexo, utilizando dados do GTFS, focando em compreender a estrutura fundamental de conectividade da rede e a resiliência do sistema de transporte público de São Paulo por meio de ferramentas da ciência de redes complexas. Seu trabalho se destaca pela aplicação de simulações de ataques direcionados e aleatórios à rede, com o objetivo de compreender sua vulnerabilidade estrutural. Foram analisadas métricas como o número de links, o grau máximo dos nós, a quantidade de componentes e o comprimento médio dos caminhos, revelando pontos críticos de conexão, padrões de conectividade e a resiliência da rede sob diferentes cenários, concluindo que a rede é robusta contra falhas aleatórias, e vulnerável à remoção de pontos por onde passam muitas linhas, como terminais de ônibus. Embora a abordagem ofereça uma leitura da estrutura e conectividade da rede, sua análise é concentrada em

aspectos estruturais e não considera a dimensão espacial detalhada da infraestrutura de paradas ou a articulação com a malha urbana. Sandro demonstra que os dados públicos disponibilizados pela SPTrans possibilitam análises profundas e sofisticadas da rede de transporte coletivo do município de São Paulo. Esse exemplo reforça a viabilidade de empregar essas bases de dados, amplamente acessíveis à população, para investigações de alto nível que contribuam com o planejamento urbano e a formulação de políticas públicas que beneficiem a população e o município.

De forma complementar, SILVA (2018) realiza a modelagem do transporte público de ônibus por meio de grafos não orientados, mapeando as principais rotas e suas conexões entre regiões político-administrativas da cidade (zonas). Seu trabalho propõe uma metodologia para representar as rotas em grafos, permitindo análises de caminhos mínimos, fluxos e identificação de regiões com maior concentração de linhas, levando em consideração os dados do transporte em horários de pico da manhã e tarde. Ao atribuir pesos aos nós com base no número de linhas conectadas, Silva infere padrões de demanda, apontando, por exemplo, a saturação nas zonas leste e sul da cidade. O trabalho representa um avanço na análise de demanda a partir da estrutura das linhas, porém, ainda se restringe à malha de ônibus e não aprofunda a integração entre diferentes modos de transporte nem a distribuição geoespacial das paradas, podendo ser melhorado com a adição de dados geográficos complementares.

Dado que esses estudos iniciais estabeleceram bases sólidas para a modelagem e análise da rede de transporte paulistana, este trabalho pretende contribuir para a gestão da mobilidade no município de São Paulo trazendo uma análise que contemple os períodos pré, durante e pós-pandemia, evidenciando mudanças e identificando pontos de melhoria a serem estudados no planejamento estratégico da malha viária da cidade, levando em conta o histórico de dados da SPTrans de 2015 a 2025. Para isso, propomos uma análise territorial detalhada da infraestrutura do transporte público, com foco na distribuição geoespacial das paradas e sua articulação com outras bases urbanas, como estações de metrô e trem, e zonas demográficas. A partir da integração de múltiplas fontes de dados, criamos uma base unificada e atualizada, que permite analisar a eficiência e viabilidade da malha de ônibus municipais ao longo dos anos, por meio de análise de redes, com a criação de grafos, e análises estatísticas descritivas, com o objetivo de elucidar e divulgar a condição e qualidade do transporte público em São Paulo. Assim, amplia-se a compreensão da estrutura do transporte público em São Paulo, oferecendo uma percepção mais atual e espacialmente detalhada da malha de mobilidade urbana.

Os objetivos específicos incluem a criação de um grafo com a rede de ônibus municipais da cidade de São Paulo, a identificação de rotas críticas, com alta quantidade de passageiros, a análise das implicações de novas estações de metrô, a análise estatística descritiva e a comparação entre a oferta de transporte e a demanda populacional. Por meio dessas análises, pretendemos investigar a eficiência e sugerir insights para o estudo de melhorias na estrutura atual, oferecendo dados e análises para o planejamento urbano e o aperfeiçoamento do transporte na cidade. Para isso, buscamos coletar, tratar e integrar dados de diversas fontes, como o GTFS e o histórico de passageiros por linha, fornecido pela SPTrans, e dados populacionais do IBGE, a fim de construir um modelo matemático da malha viária.

SUGUIY *et al.* (2020) definem o índice ESR (Efficiency/Satisfaction Ratio) como uma

medida que busca equilibrar duas dimensões fundamentais na avaliação de sistemas de transporte urbano: a eficiência operacional e a satisfação dos usuários. Segundo os autores, um sistema é eficiente quando não é possível obter uma saída sem, ao menos, uma entrada, e não mais do que isso, enquanto a satisfação representa o grau em que as necessidades dos usuários são atendidas. Priorizar apenas a eficiência pode comprometer a qualidade do serviço, tornando-o socialmente insustentável e, por outro lado, focar exclusivamente na satisfação pode elevar os custos operacionais e prejudicar a viabilidade econômica, mais especificamente, o lucro. No entanto, segundo [SCHWARTZMAN \(1975\)](#), o mercado não pode ser modelo para gestão de bens públicos, apontando que a lógica do lucro leva à ênfase em atividades rentáveis, deixando de lado necessidades sociais relevantes, e que a racionalidade política (controle social, participação, legitimidade) difere da racionalidade econômica do mercado, reforçando que o transporte público deve ser analisado pelos seus impactos sociais e a satisfação dos usuários, e não pela rentabilidade.

Neste trabalho, então, a eficiência no transporte público é entendida como a capacidade em equilibrar demanda e oferta, ou seja, a capacidade do sistema satisfazer adequadamente a demanda da população, oferecendo cobertura territorial, frequência, conforto, tempo de deslocamento e custos compatíveis com as necessidades dos usuários, resultando em maior satisfação e adesão da população ao uso de transporte público, sem que haja gastos governamentais em excesso, isto é, operando as rotas de modo a atender a demanda populacional.

O tratamento e a análise dos dados foram realizados em um notebook Dell G5, equipado com um processador Intel(R) Core(TM) i5-10500H CPU @ 2.50GHz e 16,0 GB de memória RAM. Essa configuração foi suficiente para suportar as etapas de pré-processamento, modelagem e análise estatística dos dados em ambiente local. O código-fonte desenvolvido para a coleta, tratamento e análise dos dados apresentados neste trabalho está disponível publicamente no GitHub, no seguinte repositório: <https://github.com/fran-dea/public-transport-sptrans>. A disponibilização visa garantir a reprodutibilidade dos resultados e facilitar eventuais extensões futuras da pesquisa.

Capítulo 1

Metodologia

Nesta seção, iremos discutir a ingestão e tratamento dos dados, bem como os métodos matemáticos de análise.

1.1 O General Transit Feed Specification (GTFS)

Buscando padronizar os dados de transporte público para uso no Google Maps, o Google criou, em meados de 2006, em parceria com cidades dos Estados Unidos, o formato GTFS (Google Transit Feed Specification). A partir de 2010, o termo foi alterado para não ter mais relação com o Google, tornando-se General Transit Feed Specification ([GTFS Org, s.d.](#)).

O GTFS é um formato de organização de dados que permite que agências de transporte publiquem seus dados para uso de diversos agentes, desde empresas até estudantes e planejadores de políticas públicas, permitindo que empresas como a Google forneçam aos usuários detalhes sobre as rotas, paradas e horários das linhas de transporte.




Figura 1.1: Diagrama da estrutura do GTFS.

Fonte: GTFS Org

Nessa base de dados, podemos obter tanto dados de movimento em tempo real do transporte quanto dados dos horários e rotas programadas. Para este trabalho, utilizamos as informações de horários de paradas, paradas, viagens e rotas do GTFS fornecido pela SPTrans. Para ter acesso aos dados do GTFS, é necessário fazer download de um arquivo .zip, que contém 10 arquivos no formato csv e tipo .txt, sendo necessária autenticação no site da SPTrans, que não permite scraping tão facilmente, por conta do login. Logo, para obter os dados do GTFS, teremos que fazer download manualmente através do site da SPTrans.

Além do GTFS, a SPTrans também disponibiliza a API do Olho Vivo, que oferece diversos serviços que permitem o acesso em tempo real a informações sobre o transporte público da cidade de São Paulo. Os dados são disponibilizados no formato JSON e seguem uma estrutura REST, o que facilita a obtenção massiva. Com um simples cadastro, é possível gerar uma chave para uso da API, que permite acessar dados de linhas, paradas, corredores, posição dos veículos, previsão de chegada e etc. Através de requisições com a biblioteca requests do python, conseguimos obter os dados do objeto de linhas, paradas e previsão de chegada, porém, os objetos de previsão de chegada e paradas retornam apenas dados sobre paradas em corredores de ônibus, logo, a API não fornece dados sobre todas as linhas de ônibus que são operadas pela SPTrans na cidade de São Paulo, representando uma falha na disponibilização de informações por parte da SPTrans. Uma possível melhoria da API do Olho Vivo seria a disponibilização do GTFS na API REST.

Nos arquivos `stop_times`, `stops`, `trips` e `routes`, conseguimos obter dados sobre a localização de cada parada (com as coordenadas geográficas) por linha, bem como o tipo de itinerário (sábado, domingo, DU, todos os dias), a frequência planejada dos ônibus e informações descritivas de cada linha. Após juntar todos os dados, obtemos uma tabela com as linhas, que vamos chamar de rotas, tendo 1342 valores, e uma com as viagens de cada rota, com 88534 dados. Essa será a tabela que iremos utilizar para fazer as análises iniciais.

Na seção 1.4, descobrimos que os dados estão incompletos, o que não nos permite fazer uma análise integral das rotas, já que cada GTFS é referente apenas ao mês anterior ao qual ele foi publicado. Por conta dessa inconsistência, solicitamos dados adicionais a SPTrans, tópico que será tratado na seção 1.5. Por meio dessa solicitação, conseguimos obter 10 anos de histórico do GTFS.

1.2 Dados de passageiros por linha

A prefeitura de São Paulo disponibiliza em seu site, na seção de acesso à informação¹ os dados de passageiros transportados nas linhas da capital, com granularidade diária e mensal, através de arquivos no formato xls (um formato antigo de planilhas utilizado pelo Microsoft Excel entre 97 e 2003, que ainda pode ser lido através de código ou versões modernas do Excel). Os dados são obtidos ao passar algum tipo de bilhete único na leitora dos veículos ou estações de trem e metrô. Além do total de passageiros, também há divisões entre bilhetes estudantis, gratuitos, vale comum e vale transporte, com as respectivas versões mensais: estudantil mensal, vale comum mensal, vale transporte mensal. Também há dados de pagamento feito em dinheiro, já que nesses casos, o cobrador/motorista passa o bilhete

¹ <https://capital.sp.gov.br/web/mobilidade/w/passageiros-transportados-2025>

institucional para liberar a pessoa.

Através de um processo de *web scraping*, realizamos o download dos dados diários disponíveis no site da SPTrans, sendo necessário o acesso a 10 páginas diferentes do site, com cada uma contendo os dados de um ano específico, de 2015 a 2025. No total, foram coletados aproximadamente 365 arquivos por ano, correspondentes a um arquivo por dia, abrangendo o período de 2015 a 2024. Além disso, foram obtidos dados de 235 dias do ano de 2025. O processo de download dos arquivos não pode ser 100% automatizado pois os caminhos onde podemos acessar os arquivos variam, conforme exemplo:

- 17 de janeiro de 2025: <https://prefeitura.sp.gov.br/documents/d/mobilidade/17jan2025-1.xls>
- 25 de abril de 2024: <https://www.prefeitura.sp.gov.br/cidade/secretarias/upload/25ABR2024.xls>

O processo de coleta foi relativamente rápido, com um tempo médio de 5 minutos para o download completo dos arquivos xls. No entanto, a unificação e padronização dos dados, que possuíam diferentes nomenclaturas e organizações, representaram uma etapa significativamente mais trabalhosa, exigindo cerca de 50 minutos para serem processados e consolidados. Optamos por juntar todos os dados em um único arquivo no formato parquet, que permite processamento paralelo eficiente e consultas rápidas, por serem estruturados em colunas e facilmente particionáveis (ABDELAZIZ *et al.*, 2024).

Um dos problemas que encontramos nos dados é nome das linhas. Nos arquivos disponibilizados no site, cada linha é disponibilizada da forma "Código - Nome da linha", podendo haver exceções e erros ortográficos. No nosso processo, vamos descartar o nome da linha, e obter o código com um script genérico, que funciona para a maioria, mas não todos os dados. Devido ao volume, vamos definir que essa perda é aceitável.

1.2.1 Padronização e otimização

Para ler os 3737 arquivos xls baixados, gastamos 25min27s e precisamos criar condições para tratar corretamente o cabeçalho de cada planilha. A cada ano, as informações dispostas eram as mesmas, porém, apresentadas com nomenclaturas diferentes, e às vezes com notas que ocupavam as 2 ou 3 primeiras linhas do arquivo. Inicialmente, então, lemos todos os arquivos xls e convertemos todos em parquet, buscando otimizar a leitura dos dados antes de iniciar qualquer tipo de tratamento. Apesar de encontrarmos alguns erros por arquivos corrompidos, conseguimos converter 3679 (98,44%) dos arquivos xls para parquet. A leitura dos arquivos parquet levou cerca de 46 segundos, representando uma melhoria de 3319% no desempenho.

Para obter uma única tabela, precisávamos concatenar todos os dados obtidos, o que levou a um problema de padronização dos nomes das colunas. Juntando os dados de todos os anos, havia cerca de 40 colunas diferentes, com cerca de 3 variações para cada tipo de dados. Por exemplo, para o dado "bilhete estudante", as nomenclaturas eram:

- passageiros pagantes bilhete único estudante\n\n(d)
- passageiros pagtes estudante
- soma de passageiros pagantes bilhete único estudante\n\n(d)

Acreditamos que essas diferenças ocorreram por mudanças ao longo dos anos. Para resolver esse problema, criamos um dicionário para renomear as tabelas antes de realizar a unificação.

1.2.2 Unificação

Após obtermos os 3737 DataFrames, renomeamos e concatenamos todos, o que levou 32min1s. A tabela resultante possui 25 colunas e 4.935.341 linhas, representando os dados de passageiros 2015 a 2025.

Antes de salvar o DataFrame obtido em um arquivo parquet, vamos criar a coluna `route_id` para armazenar o código da linha, que extraímos da coluna `linha` com uma generalização, conforme explicitado antes. Além disso, também vamos criar a coluna `passageiros_integracao`, somando os dados de todas as outras integrações, e atualizar as colunas `passageiros_vale_transporte`, `passageiros_comum` e `passageiros_estudante`, somando os dados mensais de cada um, além do dado `passageiros_comum_vt` para o vale transporte.

Com os dados unificados, salvamos um único arquivo parquet, que, mesmo contendo 4.935.341 linhas e 25 colunas, pode ser lido em cerca de 7s.

1.3 Dados complementares

1.3.1 Dados do IBGE

Em 2025, o IBGE disponibilizou os dados agregados por setor censitário do censo de 2022, com informações geográficas sobre os bairros de São Paulo, além de estatísticas sobre os moradores.² Foi utilizado o formato Sistemas de Informação Geográfica (SIG), que disponibiliza os dados em formatos como shapefiles ou GeoJSONs, para representar dados geoespaciais vetoriais, como pontos, linhas e polígonos. Os setores censitários de uma metrópole como São Paulo são super fragmentados, o que permite um estudo mais aprofundado dos dados.

Para realizar a leitura e manipulação desses arquivos em Python, utilizaremos a biblioteca GeoPandas, que estende a funcionalidade do Pandas para trabalhar com dados geoespaciais de forma simples e eficiente, permitindo a leitura de arquivos com shapefiles.

As estatísticas sobre a população obtidas foram as seguintes:

² <https://www.ibge.gov.br/estatisticas/sociais/populacao/22827-censo-demografico-2022.html?edicao=41852&t=resultados>

Código	Descrição
V0001	Total de pessoas
V0002	Total de Domicílios (DPPO + DPPV + DPPUO + DPIO + DCCM + DCSM)
V0003	Total de Domicílios Particulares (DPPO + DPPV + DPPUO + DPIO)
V0004	Total de Domicílios Coletivos (DCCM + DCSM)
V0005	Média de moradores em Domicílios Particulares Ocupados (Total pessoas em Domicílios Particulares Ocupados / DPPO + DPIO)
V0006	Percentual de Domicílios Particulares Ocupados Imputados (Total DPO imputados / Total DPO)
V0007	Total de Domicílios Particulares Ocupados (DPPO + DPIO)

Tabela 1.1: Variáveis de domicílios e população. Fonte: IBGE

Para o nosso trabalho, utilizaremos predominantemente o dado "Total de pessoas" na coluna v0001. Vale notar que os dados disponibilizados pelo IBGE têm uma granularidade altíssima, sendo tabelas muito pesadas, que demandam alta quantidade de memória para realizar joins espaciais.

Para utilizar os dados do Censo 2022, juntamos a coordenada geográfica das paradas com a coordenada geográfica de cada setor censitário, através de um spatial join de "within", que verifica se o ponto da coluna A está dentro do polígono B, para cada ponto da coluna A e cada polígono da coluna B. No nosso caso, vamos verificar se o polígono com a coordenada de uma parada está dentro do polígono de um setor censitário. Assim, cada parada passa a conter, adicionalmente, os atributos demográficos do bairro em que está inserida, como população total, número de domicílios e área territorial, além das colunas categóricas que identificam região, distrito e subprefeitura.

O GeoPandas oferece suporte nativo para indexação espacial utilizando o algoritmo de árvore R (R-Tree), que cria uma estrutura hierárquica baseada em caixas envoltantes mínimas (bounding boxes) das geometrias, o que permite realizar buscas espaciais de forma muito mais eficiente. Essa indexação reduz drasticamente o número de comparações diretas necessárias entre os objetos, tornando operações como sjoin e consultas espaciais (within, intersects, contains) significativamente mais rápidas mesmo em conjuntos de dados grandes (GEOPANDAS, 2024).

A aplicação do método sjoin com predicate within na base de paradas com 10 anos de histórico do GTFS levou cerca de 4,7 segundos. Idealmente, gostaríamos de fazer também um join_nearest para saber os setores censitários que ficam em até 300m das paradas, para termos um número mais real de quantas pessoas moram próximas a certas paradas. Não conseguimos executar esse join devido à alta quantidade de memória necessária: mesmo fragmentando a base, a execução extrapola a quantidade de memória de um computador com 16GB de RAM. Essa operação é significativamente mais custosa, já que ela realiza a busca do vizinho mais próximo (nearest neighbor search) em uma base muito grande. Na próxima seção, vamos executar com sucesso o mesmo método para saber quais as estações mais próximas de uma parada, logo, o problema realmente é a quantidade de dados.

1.3.2 Estações de trem e metrô

Na busca por dados das zonas de São Paulo, encontramos, no GeoSampa, mapas com dados das estações de trem e metrô já existentes e projetadas, além da localização dos terminais de ônibus. Para acessar esses dados, podemos fazer solicitações diretamente ao servidor do GeoSampa ([PREFEITURA DO MUNICÍPIO DE SÃO PAULO, 2025](#)). Decidimos salvar os dados localmente para facilitar o acesso.

Cada estação possui uma coordenada geográfica, que utilizamos para juntar com a tabela de paradas através do método `join_nearest` do Geopandas. Essa junção foi feita considerando um raio de tolerância geográfica (`buffer`) de 2 km, ou seja, qualquer parada que esteja em até 2 km de uma estação será considerada próxima dessa estação. A escolha de 2 km foi totalmente arbitrária: consideramos uma parada é próxima de um local se for necessário caminhar por menos de 20 minutos para chegar nele.

A partir dessa junção, criamos 3 colunas na tabela de paradas: estação mais próxima (criada utilizando tanto dados de estações planejadas quanto existentes), estação mais próxima atual e estação mais próxima planejada. Posteriormente, vamos analisar algumas estatísticas relacionando as estações com dados das rotas e passageiros.

1.3.3 Zonas da cidade de São Paulo

Na cidade de São Paulo, além da divisão por bairros, utiliza-se muito as 5 grande zonas: Sul, Norte, Oeste, Leste e Centro. Infelizmente, estas categorizações não estão disponíveis na base disponibiliza pelo IBGE, portanto, precisamos encontrar outra base de dados geográfica com as informações das zonas. Apesar de buscar em diversos portais, não encontramos uma base que relacione cada distrito a uma zona específica, porém, encontramos um PDF com a tabela que relaciona os distritos às zonas ([PREFEITURA DO MUNICÍPIO DE SÃO PAULO, 2008](#)). Como o PDF foi criado a partir de uma tabela com células mescladas, extraímos manualmente os dados para a criação de uma tabela com a zona, subprefeitura e distrito, já que a criação de um script para extração dos dados do PDF não é eficiente. Vamos juntar esses dados através de um simples `merge` do Pandas com a coluna com o nome do distrito na tabela de paradas após a junção com os dados do Censo 2022.

1.4 Exploração inicial dos dados: busca por inconsistências

Inicialmente, vamos verificar se aparecem inconsistências ao juntarmos os dados de passageiros, rotas e paradas. Para essa análise, vamos considerar os dados do GTFS de março de 2025 e os dados de passageiros de 01/01/2015 até 31/03/2025. Como existem, normalmente, mudanças na rede de transporte ao longo dos anos, podemos esperar encontrar inconsistências nos dados, como dados de passageiros em linhas que não existem mais em 2025. Nesta análise, vamos focar principalmente em levantar o número de linhas das quais não possuímos dados e que prejudiquem a análise. Queremos que 100% das rotas possuam dados de paradas que explicitem por onde aquela linha passa na cidade. Com esse levantamento, vamos definir se será necessário solicitar dados adicionais a SPTrans.

1.4.1 Rotas descontinuadas, sem dados ou com dados faltantes: Análise de intersecção

Uma característica dos dados que podemos analisar é a intersecção geral entre a tabela de passageiros, de rotas e de paradas. Para isso, criamos o Diagrama de Venn abaixo:




Figura 1.2: Diagrama de Venn com as intersecções de rotas entre as bases passageiros, paradas e rotas
Fonte: A própria autora

Com o diagrama, conseguimos visualizar que 1118 linhas aparecem nas 3 tabelas (passageiros, rotas e paradas), 589 aparecem apenas em passageiros e 3 aparecem apenas em rotas, 203 aparecem em passageiros e rotas (não possuem paradas) e 18 aparecem em rotas e paradas (não possuem dados de passageiros). Assim, podemos analisar de modo mais aprofundado cada um desses casos.

Rotas descontinuadas

Foram identificadas um total de **589 rotas** que estão na base de passageiros, mas não estão na base de rotas. Abaixo, apresentamos uma tabela detalhada com o número de passageiros transportados e a quantidade de dias em que temos dados das linhas:

Período	101–1.000 passageiros	1001–10.000 passageiros	≤100 passageiros	>10.000 passageiros
30–90 dias	0.0	0.0	0.0	72.0
91–365 dias	0.0	0.0	0.0	65.0
≤30 dias	3.0	12.0	2.0	176.0

continua →

Tabela 1.2: Distribuição de passageiros por período.

Período	101–1.000 passageiros	1001–10.000 passageiros	≤ 100 passageiros	> 10.000 passageiros
> 365 dias	0.0	0.0	0.0	197.0

Tabela 1.2: *Distribuição de passageiros por período. Fonte: A própria autora*

Com base nessas estatísticas, podemos afirmar que a maioria dos dados sobre linhas que estão na tabela de passageiros, mas não estão na tabela de rotas são ou de linhas que operaram durante muito tempo e transportaram muitos passageiros (33,44%) ou que operaram durante menos de um mês e transportaram muitos passageiros (29,88%). Concluímos, então, que é crucial analisar essas rotas faltantes, que foram extintas ou modificadas, para analisar a eficiência do transporte, já que um grande número de passageiros foi impactado por essas mudanças.

Rotas sem paradas

Há 203 rotas cadastradas sem informações sobre paradas. Sem esses dados, não é possível realizar análises geográficas. Ao examinar quais rotas são afetadas, identificamos, por exemplo, a linha 177H-10 (Cidade Universitária – Metrô Santana), que de fato não aparece na tabela de viagens. No entanto, observamos que há registros para a linha 177H-21, que opera aos sábados e percorre um trajeto semelhante.

A partir da análise da rota 177H, notamos que, ao considerar apenas os quatro primeiros caracteres do código da linha, o número de rotas sem paradas cai de 203 para 47. Apesar disso, utilizar essa aproximação introduz possíveis inconsistências, pois os dois últimos dígitos do código da linha são essenciais para distinguir rotas diferentes. Por exemplo, a linha 778J-10 faz o trajeto Jardim Arpoador – Metrô Barra Funda, enquanto a 778J-41 percorre Cohab Raposo Tavares – Metrô Barra Funda. Apesar de ambas passarem por trechos semelhantes e compartilharem destino final, tratam-se de rotas distintas.

Entre essas 47 linhas restantes, destacam-se as que circulam pela Cidade Universitária (8082-10, 8083-10, 8084-10 e 8085-10), além de outras de conhecimento da autora, como a 7725-10 (Lapa – Rio Pequeno), que também passa pela cidade universitária, e a 8021-10 (Jardim Maria Luiza – Butantã). A ausência de dados completos no GTFS inviabiliza qualquer análise dessas linhas. Portanto, possivelmente, há um problema de ingestão dos dados por parte das empresas que operam as linhas, que possivelmente não cadastraram todos os dados necessários para a operação de cada linha.

Essa lacuna representa uma falha de transparência e cuidado na disponibilização de dados sobre o transporte público na maior metrópole da América Latina, onde mais de 20 milhões de pessoas circulam diariamente. Para cobrir essa lacuna, solicitamos a SPTrans o envio dos dados históricos do GTFS, que será tratada na seção 1.5.

Rotas sem passageiros

Notamos que todas as rotas que não possuem dados de passageiros, mas possuem dados de paradas, são, na verdade, erros de digitação. Todas estão duplicadas na tabela de rotas, como o exemplo abaixo:

route_id	route_long_name
909T1	Term. Pinheiros - Term. Pq. D. Pedro Ii
909T10	Term. Pinheiros - Term. Pq. D. Pedro Ii

Tabela 1.3: Rotas sem passageiros. Fonte: A própria autora

Desse modo, vamos desconsiderar esses dados ausentes.

Rotas sem passageiros e paradas

Há apenas 3 rotas sem passageiros e paradas, sendo uma delas o Circular Turismo. Podemos notar que também parece haver erro de digitação no id das rotas, já que todas as que operam na cidade possuem 6 dígitos. Também vamos desconsiderar essa ausência de dados.

route_id	route_short_name	route_long_name
83001	8300-1	Term. Pirituba - Term. Lapa
909T1	909T-1	Term. Pinheiros - Term. Pq. D. Pedro Ii
CT011	CT01-1	Circular - Turismo

Tabela 1.4: Rotas sem passageiros e paradas. Fonte: A própria autora

1.5 Solicitação de dados ao Serviço de Informação ao Cidadão

A partir da identificação de 589 rotas descontinuadas e 206 rotas sem dados de paradas, criamos uma solicitação ao Serviço de Informação ao Cidadão por meio eletrônico (SIC-e) para recebermos o histórico de dados do GTFS de janeiro de 2015 a março de 2025, o qual possui prazo para ser processado de até 20 (vinte) dias, estabelecido no § 2º do art. 18 do Decreto Municipal 53.623/2012. Obtivemos resposta após 18 dias corridos da solicitação.

Recebemos, da SPTrans, o acesso aos dados solicitados por meio do Google Drive, com arquivos mensais, tendo os dados do GTFS de janeiro de 2015 a março de 2025, sendo cada arquivo no mesmo formato daquele disponibilizado na seção para desenvolvedores da SPTrans. Além disso, a empresa demonstrou interesse em conhecer o trabalho acadêmico desenvolvido e indicou o contato do responsável pela Gerência de Avaliação de Transporte e Experiência do Usuário, para eventual compartilhamento dos resultados.

A partir dos dados enviados, buscamos construir uma base histórica do GTFS que permita, para qualquer data específica, associar as informações de uma determinada linha aos passageiros que a utilizaram.

Como a solicitação dos dados ao SIC-e teve origem em inconsistências previamente identificadas, nosso objetivo agora é avaliar se essas inconsistências persistem.

1.5.1 Análise das inconsistências

Ao replicar a mesma análise que fizemos na seção 1.4, verificamos que a maior parte dos registros (1.570) está presente simultaneamente nas três bases (passageiros, rotas e paradas). Isso representa um aumento de 40% na intersecção entre elas, indicando uma boa integração e maior consistência dos dados.




Figura 1.3: Diagrama de Venn com as intersecções de rotas entre as bases passageiros, paradas e rotas
Fonte: A própria autora

Ainda assim, a base de passageiros contém 326 linhas que não aparecem nas bases de rotas ou paradas. Embora esse número seja menor que os 589 registros identificados anteriormente, ele ainda sugere a presença de dados incompletos. Além disso, há intersecções parciais de menor relevância: 14 registros aparecem apenas entre passageiros e rotas, e 24 entre rotas e paradas. Vale destacar que não há linhas exclusivas das tabelas de rotas ou paradas, nem linhas que apareçam apenas nas bases de passageiros e paradas.

Das 589 linhas que anteriormente não haviam sido identificadas na tabela de passageiros e que não aparecem na tabela de rotas ou paradas, 326 continuam sem dados associados. Ao analisarmos o período de operação dessas linhas, verificamos que a maioria se refere a linhas temporárias, que funcionaram por menos de um mês. Apesar do curto período de atividade, essas rotas transportaram um número relevante de passageiros e, provavelmente, foram posteriormente substituídas por linhas permanentes ou reconfiguradas dentro do sistema de transporte, aparecendo no GTFS com outro nome.

Quanto as outras 14 linhas que possuem dados de paradas mas não de passageiros, vamos desconsiderar da análise. Já nas linhas que possuem dados de passageiros e rotas, mas não de paradas, observamos uma diminuição da inconsistência de mais de 93%, sobrando apenas 14 linhas das 203 levantadas anteriormente.

passageiros período	1001-10000 passageiros	101-1.000 passageiros	<=100 passageiros	>10.000
30-90 dias	0.0	0.0	0.0	20.0
91-365 dias	0.0	0.0	0.0	10.0
<=30 dias	10.0	2.0	2.0	164.0
>365	0.0	0.0	0.0	56.0

Tabela 1.5: *Quantidade de passageiros por tempo de operação das linhas. Fonte: A própria autora*

Como já possuímos o histórico completo do GTFS fornecido pela SPTrans, vamos descartar os registros com as inconsistências mencionadas nessa seção.

1.6 Descrição da estrutura final dos dados

1.6.1 Rotas

A tabela de rotas contém informações sobre as linhas de ônibus operantes no município de São Paulo ao longo do período de janeiro de 2015 a março de 2025. Possui 167.346 registros distribuídos em 8 colunas, contendo atributos como o identificador da rota (*route_id*), identificador da agência (*agency_id*), nome curto e nome completo da linha (*route_short_name*, *route_long_name*), tipo de rota (*route_type*), além de dados de cores utilizadas (*route_color* e *route_text_color*).

A coluna *data_referencia* indica o mês e ano onde a rota existiu no GTFS. Notamos que as colunas de cores apresentam valores ausentes em datas mais antigas, sendo esse um valor preenchido apenas nos dados mais recentes.

1.6.2 Paradas

A tabela de paradas de ônibus possui informações detalhadas sobre cada parada realizada pelas viagens das rotas, entre janeiro de 2015 e março de 2025. Com 11.849.701 registros e 13 colunas, seu tamanho total ultrapassa 1 GB.

Os dados incluem identificadores de rota (*route_id*), viagem (*trip_id*), serviço (*service_id*), direção da viagem (*direction_id*) e sequência da parada (*stop_sequence*), além de informações textuais como o nome e a descrição da parada (*stop_name*, *stop_desc*). Também estão presentes as coordenadas geográficas (*stop_lat*, *stop_lon*). A coluna *data_referencia* indica o mês e ano onde a parada existiu no GTFS.

1.6.3 Passageiros

A tabela correspondente ao histórico de passageiros transportados fornece uma visão detalhada da demanda por linha de ônibus ao longo do tempo, abrangendo o período de 1 de janeiro de 2015 a 07 de setembro de 2025. Com um total de 5.056.912 registros distribuídos em 25 colunas, seu volume de dados ultrapassa 1 GB.

As colunas registram, para cada linha e data específica, a quantidade de passageiros segmentada por tipo de pagamento e perfil do usuário, como *passageiros_dinheiro*, *passageiros_comum*, *passageiros_valetransporte*, *passageiros_estudante* e *passageiros_gratuitos*, entre outras. Além disso, há colunas de totalizações como *passageiros_pagantes*, *passageiros_total* e *passageiros_integracao*, permitindo a análise de diferentes perfis de uso do transporte público. As variáveis *empresa*, *linha*, *area*, *grupo*, *lote* e *route_id* fornecem informações complementares sobre a operação do sistema e sua organização espacial e institucional. A coluna *data* representa a data para a qual o registro de passageiros de uma respectiva linha se refere, com granularidade diária.

1.6.4 População

A base de dados referente à população por bairro, obtida a partir do Censo Demográfico de 2022 do IBGE, contém 17.576 registros e 27 colunas, organizadas como um *GeoDataFrame* da biblioteca *GeoPandas*, o que possibilita a realização de análises espaciais. A tabela inclui identificadores e nomes de diversas divisões administrativas, como região, município, distrito, subdistrito, bairro, e região integrada, bem como a área territorial (*AREA_KM2*) e a geometria espacial correspondente a cada unidade territorial. As colunas de *v0001* a *v0007* representam indicadores populacionais e domiciliares, conforme o dicionário de variáveis disponibilizado pelo IBGE na tabela 1.1.

Para complementar esses dados, temos a subdivisão em zonas, onde, para cada distrito, atribuímos uma das 5 zonas: Norte, Sul, Leste, Oeste e Centro. Essa base possui 3 colunas (Regiões, Subprefeituras e Distritos) e 96 registros.

1.6.5 Estações de trem e metrô

A base de estações de trem e metrô conta com o nome da estação, o nome linha e a localização geográfica (em formato de geometria) da estação, além da indicação de estação planejada ou existente.

1.6.6 Merges

Nas tabelas de rotas, passageiros e paradas, as colunas-chave para realizar a junção das tabelas principais são *route_id* e *data* (ou *data_referencia*), utilizadas para associar, ao longo do tempo, os dados das rotas, paradas e passageiros transportados. A partir dessas colunas, foi possível consolidar uma estrutura temporal da operação do transporte público.

Para o restante dos dados, a base de paradas foi definida como estrutura central da modelagem, uma vez que cada registro representa um ponto geográfico ao longo do sistema de transporte. A ela foram adicionadas as demais bases por meio de junções espaciais, utilizando as coordenadas geográficas disponíveis na coluna *geometry*, principalmente por um join espacial de proximidade, conforme explicado nas respectivas seções dessas bases (1.3.1 e 1.3.2).

Essa estrutura unificada, centralizada nas paradas de ônibus, permite uma análise integrada entre demanda por transporte, localização, acesso à rede metrô-CPTM e características populacionais.




Figura 1.4: Diagrama com as tabelas do trabalho e suas relações

Fonte: A própria autora

1.7 Grafos

Nesta seção, vamos abordar o que é um grafo, por que essa estrutura é importante para nossa análise e como criar e analisar ela com os dados obtidos no trabalho.

1.7.1 Definição

Um grafo é uma estrutura usada para representar relações entre objetos, formado por um conjunto de vértices (ou nós) e um conjunto de arcos (ou arestas). Cada aresta liga dois nós, indicando uma conexão ou relação entre eles. Podemos imaginar um grafo como um mapa de transporte: os nós seriam as estações (ou paradas) e as arestas, as linhas que ligam as estações e formam uma rota, em mão única. Por exemplo, se há um arco que vai do vértice A para o vértice B, isso significa que há um caminho que sai de A e chega em B. Visualmente, podemos observar um grafo no próprio mapa da rede de trem e metrô de São Paulo:



Figura 1.5: Mapa do metrô de São Paulo

Fonte: Companhia Paulista de Trens Metropolitanos (CPTM)

1.7.2 Aplicação

Para modelar a rede de transporte público por ônibus da cidade de São Paulo, [SILVA \(2018\)](#) construiu, a partir dos dados provenientes do Bilhete Único, grafos não orientados, cujos vértices representam regiões político-administrativas da cidade e as arestas indicam as conexões viárias estabelecidas por linhas de ônibus entre essas regiões. O foco da análise foi em identificar o volume de passageiros nos horários de pico, permitindo identificar os principais fluxos de deslocamento nos períodos de maior demanda. Essa modelagem permitiu a visualização das áreas mais saturadas do sistema e forneceu subsídios para análises sobre a eficiência e a cobertura do transporte público, evidenciando a aplicabilidade dos grafos na compreensão e no planejamento urbano.

De modo semelhante, vamos criar um grafo com os dados do GTFS para analisar algumas métricas de centralidade. O grafo será criado utilizando as paradas como nós, e as viagens como arestas. Como não conseguimos fazer os joins que queríamos para saber a população afetada diretamente por uma parada, vamos fazer análises mais simples, focando em métricas de centralidade do grafo.

Como criar o grafo

A Peartree é uma biblioteca feita em Python, projetada para criar grafos a partir de dados GTFS. Ela permite transformar informações sobre paradas, rotas e horários em um grafo geoespacial, facilitando análises como cálculo de rotas, centralidade de estações e conectividade da rede.

Embora a Peartree não esteja mais sendo atualizada e tenha limitações em relação a algumas funcionalidades como a integração de dados complementares de passageiros, optamos por utilizá-la devido à sua facilidade de uso e integração direta com os dados GTFS. A partir de um caminho de arquivo .zip no formato GTFS, um horário de início

e um horário final, a `peartree` devolve um objeto de grafo da biblioteca `Networkx`, que permite diversas análises com métodos já implementados.

Para o nosso trabalho, vamos criar um grafo para cada mês de dados do GTFS, com o objetivo de obter dados temporais para algumas métricas. Como o sistema é muito pesado, optamos por criar um grafo com as rotas que operam entre 06h e 08h, pegando o horário de pico da manhã. Vale notar que, mesmo com essa limitação de horário, a criação de todos os grafos e o cálculo de algumas métricas de centralidade levou cerca de 8h para executar.

Cálculo de métricas de centralidade

Para quantificar a importância de um nó, podemos calcular algumas métricas de centralidade, que foram melhor definidas e estudadas por [FREEMAN \(1978\)](#), sendo elas: Centralidade de Grau (Degree Centrality), Centralidade de Proximidade (Closeness Centrality) e Centralidade de Intermediação (Betweenness Centrality).

A Centralidade de Grau (Degree Centrality) é calculada simplesmente pela contagem do número de arestas que um nó possui. Essa medida permite avaliarmos quão importante um nó é para a rede. No nosso caso, por exemplo, nós com alta centralidade possivelmente estarão localizados em vias importantes, por onde passam várias linhas, como a Av. Paulista, Av. Rebouças, e etc.

$$C_D(v) = \frac{k_v}{N - 1}$$

onde:

- $C_D(v)$ é a Centralidade de Grau do nó v ;
- k_v é o grau do nó v (número de conexões);
- N é o número total de nós na rede.

A Centralidade de Proximidade (Closeness Centrality) avalia a importância de um nó em um contexto global, baseada no conceito de distância, sendo o inverso da soma das distâncias geodésicas (os caminhos mais curtos) de um nó a todos os outros. Nós com alta proximidade são aqueles que permitem a um passageiro chegar em outro lugar mais facilmente, pois possuem a menor distância média para alcançar o restante dos nós.

$$C_C(v) = \frac{N - 1}{\sum_{u \neq v} d(v, u)}$$

onde:

- $C_C(v)$ é a Centralidade de Proximidade do nó v ;
- N é o número total de nós na rede;
- $d(v, u)$ é a distância (caminho mais curto) entre v e u .

A Centralidade de Intermediação (Betweenness Centrality) avalia o quanto um nó atua como "ponte" ou "intermediário" nos caminhos mais curtos entre outros pares de nós,

ocupando uma posição estratégica na rede. No nosso grafo, podemos esperar que os nós em vias importantes também tenham uma alta betweenness centrality.

$$C_B(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}}$$

onde:

- $C_B(v)$ é a Centralidade de Intermediação do nó v ;
- σ_{st} é o número total de caminhos mais curtos entre s e t ;
- $\sigma_{st}(v)$ é o número desses caminhos que passam pelo nó v .

1.8 Cálculo da distância percorrida pelas rotas

Para calcular a distância percorrida por uma rota, utilizamos duas abordagens: primeiro, vamos somar a distância percorrida entre cada parada da rota, seguindo a sequência de paradas de cada viagem da rota, para saber qual o seu percurso real. Segundo, vamos calcular qual a distância máxima entre duas paradas de uma rota, para saber qual a distância que ela percorre pela cidade. Faremos isso para cada mês entre 2015 e março de 2025, para obtermos uma sequência cronológica dessas distâncias.

Para obter uma medida mais realista de proximidade entre paradas, utilizamos a distância geográfica real entre coordenadas (latitude e longitude), em vez da distância topológica (número de arestas). Essa abordagem transforma o grafo em uma estrutura espacialmente ponderada, em que cada aresta tem um peso correspondente à distância em metros entre paradas consecutivas, sendo amplamente usada em redes urbanas reais, como discutido por (BARTHÉLEMY, 2011), que destaca a importância de considerar as dimensões geográficas nas análises de conectividade. RODRIGUE (2020) também reforça que sistemas de transporte público devem ser modelados como redes geoespaciais, onde a posição das paradas influencia diretamente a eficiência do transporte.

A distância geográfica entre duas paradas $d(u, v)$ é calculada utilizando a fórmula de Haversine, que considera o raio da Terra para estimar a menor distância ao longo da superfície esférica.

$$d(p, q) = 2R \cdot \arcsin \left(\sqrt{\sin^2 \left(\frac{\Delta\phi}{2} \right) + \cos(\phi_1) \cos(\phi_2) \sin^2 \left(\frac{\Delta\lambda}{2} \right)} \right) \quad (1.1)$$

Onde:

- d : distância entre os dois pontos, em metros;
- R : raio médio da Terra, aproximadamente 6.371 quilômetros;
- ϕ_1, ϕ_2 : latitudes dos pontos 1 e 2 (em radianos);
- λ_1, λ_2 : longitudes dos pontos 1 e 2 (em radianos);

- $\Delta\phi = \phi_2 - \phi_1$: diferença de latitude;
- $\Delta\lambda = \lambda_2 - \lambda_1$: diferença de longitude.

Para implementar esses métodos em Python, utilizamos as bibliotecas `math`, `scipy` e `numpy`, além da função `geodesic` do módulo `distance` do `geopy`.

1.9 Noções estatísticas

Para entender os resultados do trabalho, vamos abordar o conceito de regressão linear e o que é e como interpretar um `boxplot`.

1.9.1 Regressão linear

A regressão linear é um dos modelos estatísticos mais utilizados para descrever a relação entre duas variáveis. Tendo em vista que não temos a população inteira, o modelo sempre será acompanhado de erros (resíduos), os quais usaremos para quantificar quão boa é nossa hipótese de que as variáveis possuem uma dependência linear. O modelo pode ser calculado por

$$\hat{y}_i = \hat{\alpha} + \hat{\beta} \times \hat{x}_i,$$

sendo os valores de $\hat{\alpha}$ e $\hat{\beta}$ calculados pelo método dos mínimos quadrados. Os resíduos do modelo podem ser calculados por

$$\hat{e}_i = y_i - \hat{y}_i,$$

e possuem média zero, variância constante (homocedasticidade), independência entre si e distribuição normal (MORETTIN e SINGER, 2019). Com essas características, podemos calcular, a partir desses resíduos, quão estatisticamente significativo é o modelo de regressão linear para os dados. Um p-valor baixo indica que a hipótese de que não há relação linear entre as variáveis é falsa, mas não implica, necessariamente, que essa relação é verdadeira (CHRISTIE ASCHWANDEN, 2015). Outra métrica que podemos avaliar é o R^2 , que indica quanto da variação dos dados é explicada pelo modelo, sendo calculada como a diferença entre 1 e a razão entre a soma dos quadrados dos resíduos e a soma do quadrado dos dados (MORETTIN e SINGER, 2019). Para a implementação desses estudos neste trabalho, usamos o módulo `linregress` da biblioteca de Python `scipy.stats` e, para identificar a normalidade dos resíduos, utilizamos o QQ Plot, um gráfico que compara os resíduos da regressão com a distribuição normal teórica. Se os pontos estiverem próximos da linha diagonal, os resíduos seguem aproximadamente uma distribuição normal, grandes desvios indicam não normalidade.

1.9.2 O boxplot

O `boxplot`, introduzido por TUKEY (1977) permite visualizar a distribuição de um conjunto de dados e identificar valores atípicos. Ela resume os principais atributos dos

dados através de 5 estatísticas principais: o mínimo, o máximo, a mediana, o primeiro quartil e o terceiro quartil.




Figura 1.6: Ilustração dos atributos de um boxplot. Fonte: Numiqo.

Neste trabalho, utilizaremos o boxplot para visualizar a distribuição de métricas dos dados, de forma a não nos prendermos apenas na média ou mediana, principalmente quando considerarmos o alto volume de 10 anos de dados.

Capítulo 2

Resultados

2.1 Estatísticas e análises gráficas

A partir dos dados obtidos do GTFS, dos dados de passageiros disponibilizados pela prefeitura e dos dados do Censo de 2022, do IBGE, podemos criar algumas visualizações gráficas simples, para nos auxiliar a entender as mudanças que ocorreram ao longo do tempo e as possíveis associações que podemos fazer juntando essas 3 bases de dados.

2.1.1 Quantidade de linhas e paradas ao longo do tempo

Inicialmente, podemos visualizar qual a quantidade de paradas e rotas únicas nas bases do GTFS ao longo do tempo.




Figura 2.1: Histórico da quantidade única de rotas e paradas ao longo do tempo. Fonte: A própria autora.

Conseguimos observar um crescimento contínuo no número de paradas, indicando que, mês a mês, a quantidade de locais únicos que o transporte cobre aumenta, o que

pode ter sido causado por novas linhas ou pela expansão de linhas já existentes. Já a quantidade de rotas tinha uma tendência decrescente até 2020, e levemente crescente a partir de 2020, podendo indicar que muitas linhas foram extintas ou reestruturadas, e que mais recentemente o sistema tem se expandido.

Vale notar que há quedas bruscas na quantidade de rotas em alguns períodos de 2016, 2019 e 2020, indicando possíveis reestruturações temporárias da rede, ou a ausência de dados.

Como temos dados geográficos mais detalhados, podemos analisar as mesmas métricas com segregações por zonas, bairros e estações próximas:

Divisão por zona




Figura 2.2: Histórico da quantidade única de rotas e paradas ao longo do tempo por zona. Fonte: A própria autora.

Observamos que as regiões Sul e Leste concentram a maior quantidade de paradas e rotas de ônibus, o que reflete a sua extensão territorial e alta demanda populacional. Enquanto o número de paradas cresce de forma contínua em todas as regiões (menos o centro), o número de rotas apresenta pequenas oscilações, com uma queda mais acentuada na região Sul.

Vale notar que a queda brusca na quantidade de rotas observada no gráfico 2.1 não é tão visível no gráfico por zonas, possivelmente por haver rotas que passam por mais de uma região.




Figura 2.3: *Quantidade de rotas por regiões em todo o histórico da base. Fonte: A própria autora.*

No gráfico acima, podemos ver que muitas rotas passam por mais de uma região, inclusive, vale notar que a quantidade de rotas que passa exclusivamente pela região Oeste é menor do que a que passa pela Oeste e Norte, e Oeste e Sul. As zonas Sul, Leste e Norte dominam em quantidade de rotas que passam exclusivamente por elas. Também podemos notar que nenhuma rota passa exclusivamente pelo Centro. Dentre as rotas que passam por 4 regiões, a combinação mais comum é Centro, Leste, Norte e Oeste, com 8 rotas.

Divisão por bairro




Figura 2.4: Histórico da quantidade única de rotas e paradas ao longo do tempo por bairro. Fonte: A própria autora.

Entre os distritos com mais paradas, destacam-se Grajaú e Itaquera, ficando no topo do ranking ao longo de toda a série histórica. Já entre as rotas, destacam-se Grajaú e Capão Redondo. Apesar de Itaquera possuir muitas paradas, há poucas linhas, indicando que a região é atendida por linhas estruturadas para serem mais longas, possivelmente tendo

percursos maiores. No gráfico abaixo, podemos observar que a distância média das rotas que passam em Itaquera é de 27.47 km, enquanto que a média da cidade é de 23.63 km. Essa diferença de quase 4 km ilustra o maior percurso das rotas do bairro.




Figura 2.5: Comparação entre a média das distâncias percorridas entre as rotas de Itaquera e as da cidade ao longo do tempo. Fonte: A própria autora.

Divisão por proximidade a trem e metrô

Podemos buscar analisar quais estações de metrô ou trem possuem os maiores números de rotas próximas, para entender a importância da integração desses transportes e os possíveis impactos de novas estações.




Figura 2.6: Histórico da quantidade única de rotas e paradas ao longo do tempo por estação mais próxima nas estações futuras. Fonte: A própria autora.

Entre as estações planejadas, Campo Limpo e Jardim Ângela se destacam por apresentarem o maior número de paradas e rotas próximas, mantendo-se no topo do ranking ao longo de toda a série histórica. A estação Campo Limpo já existe na Linha Lilás, mas também há planos de construir uma integração com a futura linha ALPHAVILLE - CAMPO LIMPO. Já o Jardim Ângela conta com uma ampla rede de transporte, possuindo um terminal de ônibus, e se beneficiaria muito de uma nova estação de metrô que encurtasse

o percurso da população, afinal, apesar de ser mais caro que os ônibus, o metrô é mais rápido e eficiente ao transportar passageiros.




Figura 2.7: Histórico da quantidade única de rotas e paradas ao longo do tempo por estação mais próxima nas estações futuras e atuais. Fonte: A própria autora.

Quando observamos o ranking utilizando dados tanto das estações existentes quanto das futuras, podemos ver que o Jardim Ângela segue sendo o líder em quantidade de rotas e paradas, ou seja, é uma região que se beneficiaria muito da construção da estação.

Segundo o **METRÔCPTM** (2024), a estação Jardim Ângela da Linha Lilás tem início de operação planejado para 2028.

De acordo com a **AGÊNCIA MURAL** (2025), "Atualmente, o trecho entre o Jardim Ângela até a estação Santa Cruz leva, em média, 1h15 para ser percorrido de ônibus e metrô. Segundo estudo realizado pela Via Mobilidade, após a conclusão das obras, os passageiros levarão cerca de 33 minutos entre o Jardim Ângela e a estação Chácara Klabin." Considerando que a estação Santa Cruz é uma antes da Chácara Klabin, podemos considerar que o percurso do Jardim Ângela até a Santa Cruz levaria cerca de 30 minutos de metrô, uma otimização de 46%.

Como podemos ver no boxplot abaixo, as rotas que do distrito Jardim Ângela possuem uma alta quantidade de passageiros, com muitos outliers acima de 600 mil passageiros por mês. O Jardim Ângela possui uma das linhas que transporta mais passageiros mensalmente, fato que abordaremos mais para frente na seção de rankings. A matéria prevê que um pico de 62 mil pessoas utilizem a estação por dia, sendo que a região possui mais de 311 mil moradores, segundo o censo de 2022.




Figura 2.8: Boxplot da quantidade de passageiros nas rotas que passam no distrito Jardim Ângela.
Fonte: A própria autora.

2.1.2 Novas linhas e paradas ao longo do tempo

Como temos o histórico de 10 anos de paradas e rotas, podemos criar uma base que nos diga quantas paradas e rotas novas surgiram em dado mês, utilizando dados do mês anterior. Com exceção de janeiro de 2015, podemos fazer isso para todos os meses subsequentes, até março de 2025.

No gráfico abaixo, é possível ver que a quantidade de paradas e rotas novas aumentou quase constantemente ao longo do tempo, com exceções em alguns meses, onde possivelmente houve uma reestruturação. Vale notar que a quantidade de meses em que a quantidade de rotas excedeu o padrão quase constante é muito maior que os meses em que a quantidade de paradas excedeu o padrão quase constante. Uma possível explicação

para isso é assumir que rotas são mais propensas a serem reestruturadas e criadas do que paradas, já que as rotas dependem das paradas, ou seja, é mais fácil criar uma rota nova que atenda paradas já existentes e algumas paradas novas, do que criar uma parada nova e tentar encaixar ela em rotas já existentes.




Figura 2.9: Quantidade de novas paradas e rotas ao longo do tempo. Fonte: A própria autora.

Para essa métrica, também podemos analisar o gráfico discriminado por região (zona), bairro (distrito) e estação próxima. Para as estações, consideraremos apenas as que já existem, já que não faz tanto sentido considerar que ocorreu um replanejamento do sistema de transporte para estações que não existem ainda.

Divisão por região




Figura 2.10: Quantidade de novas paradas e rotas ao longo do tempo por região. Fonte: A própria autora

Pela primeira vez, vemos que a Zona Oeste e o Centro se destacam. Ambas apresentam uma maior quantidade de rotas novas ao longo do tempo, sem necessariamente ter um aumento no número de paradas, o que pode significar que essas duas regiões receberam uma maior atenção do planejamento de transporte. Vimos anteriormente que as zonas

Leste e Sul possuem um alto número de rotas e paradas totais, mas vemos aqui que elas não possuem tanto destaque no número de novas rotas e paradas.

Divisão por bairro




Figura 2.11: Quantidade de novas paradas e rotas ao longo do tempo por bairro. Fonte: A própria autora

Nos gráficos por bairro, notamos uma dominância de Santo Amaro e Itaquera nas novas rotas, demonstrando que as duas regiões foram alvos de um recente planejamento

mais intensivo do transporte.

Divisão por estação mais próxima




Figura 2.12: Quantidade de novas paradas e rotas ao longo do tempo por estação mais próxima (considerando apenas as existentes). Fonte: A própria autora

Por fim, ao analisar os gráficos de novas rotas próximo a estações, notamos uma leve dominância da estação Capão Redondo. Em especial, em 2018, houve mais de 25 linhas

novas próximas a estação. Podemos levantar a hipótese de uma reestruturação após a concessão para a ViaMobilidade, que ocorreu no mesmo período, mas não encontramos nada que prove essa hipótese.

2.1.3 Correlação com a população

Mês a mês, podemos calcular quantas pessoas moram no subdistrito ao qual uma parada pertence. Como a cidade de São Paulo é muito fragmentada, o número de subdistritos é alto. A partir desses dados, podemos analisar a correlação entre a quantidade total de rotas ou paradas, e a soma da população imediatamente relacionada a elas.

A princípio, podemos supor que, quanto maior o número de paradas, maior a quantidade de pessoas afetadas por essas paradas. Caso essa relação linear positiva não exista, vamos concluir que o sistema de transporte está criando paradas não eficientes, muito próximas, que atendem ao mesmo número de pessoas, ou seja, concentrando as paradas em um único local, ao invés de expandir o alcance do transporte para afetar mais pessoas. Desse modo, para testar essa hipótese, elaboramos o gráfico abaixo:




Figura 2.13: Correlação entre a quantidade de paradas e a quantidade de população imediatamente afetada. Fonte: A própria autora

Através do gráfico, podemos concluir que quanto maior o número de paradas, maior população afetada, implicando que o sistema está se expandindo de forma eficiente, criando paradas novas em locais onde não havia paradas anteriormente.

Podemos fazer a mesma hipótese para a relação entre quantidade de rotas e população afetada:




Figura 2.14: Correlação entre a quantidade de rotas e a quantidade de população imediatamente afetada. Fonte: A própria autora

No gráfico acima, podemos observar que o número de pessoas diretamente afetadas pelas rotas não está diretamente relacionado com o número de rotas, o que pode nos dizer que há uma possível desigualdade na distribuição do transporte em relação à densidade populacional, ou seja, não devem surgir rotas que façam caminhos totalmente novos, atingindo mais pessoas, mas sim reestruturações de rotas para cobrir áreas que já eram cobertas por outras rotas, mostrando que o sistema pode se tornar mais fragmentado.

2.1.4 Análise geral das rotas

Podemos analisar a distribuição de rotas discriminada por categorias como qual a cor da rota, se ela é noturna, se ela é circular, quantas horas ela opera, se ela atua em dias úteis, todos os dias ou apenas no final de semana e, por fim, uma nuvem de palavras para analisar os nomes mais frequentes nas rotas.

Rotas por cor

A SPTrans dividiu a cidade de São Paulo em 8 áreas, e atribuiu uma cor para cada uma, conforme a imagem abaixo. Cada ônibus, portanto, segue essa padronização para a identidade visual externa.




Figura 2.15: Mapa da divisão da cidade por cores. Fonte: Band Jornalismo

Quando analisamos a distribuição das rotas por cor, vemos que ela é praticamente uniforme pela cidade, com uma leve dominância das rotas azul claro (Sul), vinho (Sudoeste) e amarelo (Nordeste).




Figura 2.16: Gráfico de pizza da quantidade de rotas por cor da rota. Fonte: A própria autora.

Rotas noturnas

Podemos listar quantas rotas são ou não noturnas. Atribuiremos que uma rota é noturna caso ela opere entre 02h e 03h da manhã.

Tipo	Qtd de rotas	Porcentagem
Não noturna	1168	74%
Noturna	411	26%

Tabela 2.1: Quantidade de rotas noturnas. Fonte: A própria autora.

De forma inesperada, 26% das rotas têm horário de operação noturno. Para essas rotas, vamos analisar qual a distribuição dos horários de operação, para verificar se há muitas rotas que são apenas noturnas (operam poucas horas no dia), ou se essa porcentagem foi inflada por rotas que operam no período diurno e noturno:




Figura 2.17: Horário de operação das rotas noturnas. Fonte: A própria autora.

Como podemos ver no gráfico acima, muitas das rotas noturnas operam apenas no horário noturno, entretanto, temos que cerca de 50% das rotas consideradas noturnas operam mais que 19 horas por dia. Logo, nossa suspeita inicial estava correta, e realmente há muitas rotas que não são apenas noturnas na contagem das rotas noturnas, o que explica por que temos cerca de 25% das rotas da cidade consideradas noturnas.

Rotas circulares

Podemos listar quantas rotas são ou não circulares. Atribuímos que uma rota é circular caso ela tenha apenas uma direção na base de viagens.

Direção	Qtd de rotas
Circular	497
Não circular	1082

Tabela 2.2: Quantidade de rotas por direção. Fonte: A própria autora.

A maioria das rotas é não circular. Uma possível hipótese é que as rotas circulares percorrem distâncias menores do que as não circulares, uma vez que seu objetivo pode ser a conexão de pontos dentro de um mesmo bairro, e não a ligação entre diferentes regiões da cidade.




Figura 2.18: Média da distância percorrida por rotas, sendo elas circulares ou não. Fonte: A própria autora.

Logo, concluímos que a maioria das rotas da cidade é não circular, e a média das distâncias que as circulares percorrem é cerca de 10 km menor que a média das não circulares.

Frequência de operação

Utilizando todos os dados históricos do GTFS, podemos avaliar qual a distribuição das frequências de operação das rotas ao longo do dia.




Figura 2.19: Boxplot da frequência de operação das linhas por horário considerando todo o histórico do GTFS. Fonte: A própria autora.

Podemos notar que, durante a noite, a maioria das rotas opera com frequência entre 30 minutos e 1 hora. Entre 04h e 23h59, temos algumas linhas outliers, que operam a cada 60 minutos, e a maioria ficando, na mediana, entre 10 e 20 minutos. Além disso, a variabilidade em algumas horas é grande, indicando que algumas rotas funcionam muito diferente das outras no mesmo horário.

Esses dados são surpreendentes pois a impressão que temos é de que as linhas operam com frequências muito maiores do que o mostrado no gráfico. Vale lembrar que horários programados são diferentes dos horários reais das linhas, que podem sofrer alterações devido ao trânsito e serem replanejadas ao longo do dia. Também é comum que o ônibus de um horário se atrase, e acabe passando junto com o ônibus do próximo horário.

Vamos elaborar o mesmo boxplot para as rotas que circulam na região Oeste, em particular, as que circulam na subprefeitura do Butantã, para buscar entender se essas estatísticas mudam conforme os locais que consideramos.




Figura 2.20: Boxplot da frequência de operação das linhas da subprefeitura do Butantã por horário.
Fonte: A própria autora.

Podemos observar que a distribuição das frequências é diferente nas rotas que passam no Butantã. Essa diferença é mais perceptível em horários de pico, como entre 09h e 09h59 e entre 18h e 18h59, período em que as rotas do Butantã operam mais lentamente do que as rotas de toda a cidade.

Dias de operação

Vamos analisar qual a distribuição das rotas por dia de operação. Imaginamos que a maioria das rotas opere todos os dias.



Figura 2.21: Gráfico de pizza dos dias de operação das rotas considerando todo o histórico do GTFS.
Fonte: A própria autora.

Tabela 2.3 – continuação	
Palavra	Frequência
barra	57
varginha	53
carrão	52
itaim	50
cachoeirinha	50
sacomã	47
joão	46
maria	45

2.1.5 Ranking de rotas

Podemos rankear as rotas com diversas variáveis: nessa seção, vamos elaborar visualizações para analisar quais rotas possuem mais passageiros e maior distância percorrida. Não vamos analisar o ranking das linhas que tem menos passageiros ou menor distância percorrida pois, ao analisar a base, notamos que não há um ranking claro, devido a inconsistências como rotas que operaram por pouco tempo ou que possuem dados faltantes.

Ranking de rotas por passageiros

Para tornar a comparação mais justa com as rotas que foram surgindo ao longo dos anos, vamos criar o ranking com base na média mensal de passageiros, utilizando o total de passageiros que pegaram uma rota.

Linha	Qtd de passageiros
431010 - E.T.ITAQUERA/TERM PQ D PEDRO	768.837
675K10 - TERM JD ANGELA-METRO STA CRUZ	730.417
220210 - HOSP ITAIM/GUAIAZAZES	691.478
691310 - TERM BANDEIRA/TERM VARGINHA	667.461
607C10 - JD MIRIAM/SHOPP MORUMBI	651.849
870010 - T CAMPO LIMPO/PCA R D AZEVEDO	619.228
600010 - TERM PARELHEIROS/TERM SANTO AM	617.841
431310 - T CID TIRADENTES/T PQ D PEDRO	610.069
978T10 - JD GUARANI/METRO BARRA FUNDA	585.280
376310 - TERM VL CARRAO/METRO TATUAPE	574.801

Tabela 2.4: Ranking das top 10 linhas com mais passageiros mensalmente em média. Fonte: A própria autora.

Creio que não seja surpresa, ao menos para moradores de São Paulo, que as linhas mais movimentadas estão em regiões como Itaquera, Jd. Ângela, Guaianazes, Campo Limpo, Parelheiros, Cidade Tiradentes e etc, pois são regiões superpopuladas. Vale notar que todas as linhas no ranking fazem o transporte de um bairro para o centro ou o metrô, ou seja, são linhas necessárias para transportar os moradores de seus bairros até o trabalho.

Ranking de rotas por distância percorrida

Para saber quais são as rotas que percorrem as maiores distâncias na cidade, vamos utilizar a distância percorrida pelo dado mais recente da rota. Então, por exemplo, se uma rota existiu entre 2015 e 2018, vamos utilizar o dado de distância percorrida por ela no último mês de 2018 em que ela existiu. Assim, conseguimos contemplar os dados mais recentes de cada rota, sem deixar de fora as rotas que foram reestruturadas ao longo de 10 anos de base.

Id da rota	Nome da rota	Distância percorrida
331010	Term. Amaral Gurgel - Cidade Tiradentes (circular)	90.228783
213C10	Vl. Califórnia - Itaim Paulista	75.915440
477P10	Ipiranga - Rio Pequeno	70.842332
695Y10	Term. Parelheiros - Metrô Vl. Mariana	68.280425
400251	Guaianazes - Pq. D.pedro II	67.346256
345910	Itaim Paulista - Term. Pq. D.pedro II	64.141479
536210	Pq. Res. Cocaia - Pça. Da Sé	63.219958
393H10	Term. Amaral Gurgel - Jd. Sto André	62.951140
353910	Cid. Tiradentes - Metrô Bresser	62.516246
957T10	Cohab Taipas - Itaim Bibi, Cohab Taipas - Vl. Olímpia	61.882924

Tabela 2.5: Ranking das top 10 linhas com maior distância percorrida. Fonte: A própria autora.

A primeira linha, 331010, foi extinta em 2015, por uma reestruturação da SPTrans. Essa linha tinha operação exclusivamente noturna, e era conhecida como "Rainha da Madrugada", operando do centro até a Cidade Tiradentes, e transportando 10 mil passageiros por mês, com frequência de 1h. Vale notar que, pela linha ser circular, a distância é calculada considerando a ida e volta. Ainda, segundo o [G1 \(2014\)](#), a linha possuía 102 km, número que difere em 12 km a distância que calculamos. possivelmente, essa discrepância aparece por diferenças no método de cálculo.

A segunda linha, 213C10, que ligava a Vila Califórnia ao Itaim Paulista, foi extinta em 2018. Ela atravessava a cidade e não era circular, ou seja, eram 75km na ida e 75km na volta, totalizando 150 km percorridos.

A terceira linha com maior distância percorrida é a 477P10, que existe até atualmente, e liga o Rio Pequeno ao Ipiranga, passando por pontes importantes como o Museu do Ipiranga, diversas estações de Metrô, a Faria Lima e a Raposo Tavares. Essa linha também não é circular.

2.1.6 Análise de centralidade

A partir dos grafos criados com a biblioteca Peartree, que consideram as rotas que operam entre 06h e 08h (todas as rotas diurnas, com maior fluxo de passageiros), podemos analisar algumas métricas centralidade. Essas métricas foram calculadas mês a mês para cada parada (nó) do grafo, resultando em uma tabela com o identificador único da parada, a data as respectivas métricas de centralidade: Betweenness Centrality, Degree Centrality e Closeness Centrality.

Análise temporal

Como nossos dados são discriminados mês a mês, podemos buscar entender como as métricas de centralidade variaram ao longo do tempo. Inicialmente, vamos agrupar por ano, para facilitar a visualização:




Figura 2.23: Boxplots da média de betweenness centrality por ano. Fonte: A própria autora.

Como o betweenness centrality retrata o quanto um nó atua como ponte ou intermediário no fluxo da rede, podemos concluir que entre 2015 e 2017, o sistema apresentava valores elevados de betweenness centrality, com alta variância, com uma forte centralização estrutural da rede, em que poucos nós, que desempenhavam papel predominante na conectividade do sistema. A partir de 2018 ocorreu uma redução drástica desses valores, acompanhada de uma diminuição da variabilidade entre os nós, sugerindo que houve uma reestruturação para fragmentar a rede e distribuí-la melhor, ou seja, as paradas pararam de ser tão centrais e foram melhor planejadas para conectar a rede, que também se expandiu. Podemos correlacionar isso com a quantidade de paradas existentes no sistema mês a mês:




Figura 2.24: Correlação entre o log da média mensal da betweenness centrality e a quantidade mensal de paradas no sistema de transporte. Fonte: A própria autora.

Podemos concluir, então, que as duas métricas tem uma relação: há uma tendência negativa, quando a rede tem mais paradas, ela fica menos centralizada, com menos dependência de poucos nós críticos. O $R=-0,91$ e o $p\text{-valor}=1,961 \times 10^{-48}$ nos mostra que a relação é estatisticamente significativa. Através do gráfico abaixo, também podemos observar que os resíduos da regressão se aproximam de uma distribuição normal.




Figura 2.25: *QQ Plot ilustrando a normalidade dos resíduos. Fonte: A própria autora.*

Intuitivamente, a correlação faz sentido, pois quanto mais paradas o sistema tem, maior é a cobertura da cidade, e menos central cada parada será, dado que cada uma se torna menos crítica para conectar diferentes áreas, caso haja uma boa distribuição pelo espaço e rotas.




Figura 2.26: *Boxplots da média de degree centrality por ano. Fonte: A própria autora.*

A distribuição de degree centrality da rede permaneceu praticamente constante ao

longo do tempo, indicando que a conectividade das paradas permaneceu estável, ou seja, cada parada mantém aproximadamente o mesmo número de conexões, sem grandes mudanças na estrutura. Notamos apenas alguns outliers a mais em 2017 e 2018, período em que, aparentemente, houve uma reestruturação da rede.




Figura 2.27: Boxplots da média de closeness centrality por ano. Fonte: A própria autora.

O gráfico mostra que a closeness centrality diminuiu consistentemente ao longo dos anos, indicando que a rede de transporte se tornou menos centralizada. Entre 2015 e 2017, alguns nós eram muito próximos de todos os outros. A partir de 2018, quando suspeitamos ter ocorrido uma reestruturação, os valores ficaram mais baixos e com menos variância, sugerindo que a rede se tornou mais equilibrada, com menor dependência de pontos específicos para conectar o sistema. Essa conclusão é idêntica a que obtivemos ao analisar a métrica de betweenness centrality.

2.1.7 Análise geral dos passageiros

Buscando analisar a distribuição geral da quantidade de pessoas que utilizam o transporte ao longo dos anos, elaboramos algumas visualizações:




Figura 2.28: Quantidade mensal de passageiros por ano. Fonte: A própria autora.

A partir do gráfico acima, podemos concluir que a maioria das linhas transporta até 200 mil passageiros por mês, tendo muitos outliers, e que houve uma queda abrupta de passageiros em 2020, sendo que desde então, ano a ano, a quantidade de passageiros tem aumentado, mas ainda está distante do patamar pré pandemia. Desconsideramos 2025 pois ainda não temos dados do ano inteiro.

Como os dados de passageiros são discriminados por várias categorias, podemos tentar visualizar qual o impacto de cada categoria no total de passageiros:




Figura 2.29: Quantidade mensal de passageiros por categoria. Fonte: A própria autora.

Primeiramente, podemos concluir que há algumas inconsistências nos dados: a quantidade de passageiros em vale transporte está zerada, e os dados de passageiros que fazem integração do metrô e CPTM estão mais baixos que o esperado. Tirando essas categorias, podemos notar que há muitos passageiros que fazem integrações entre ônibus (pegando mais que um ônibus para completar o seu trajeto), tendo muitos outliers, e que a maioria dos passageiros é pagante. Para as categorias de passageiros com gratuidade e que pagam com dinheiro vamos elaborar visualizações separadas.




Figura 2.30: Quantidade mensal de passageiros pagando em dinheiro. Fonte: A própria autora.

Podemos notar que a quantidade de passageiros que paga em dinheiro vem diminuindo ao longo dos anos, e que temos ausência de dados nas bases.




Figura 2.31: Quantidade mensal de passageiros com gratuidade. Fonte: A própria autora.

Já no gráfico de passageiros com gratuidade, observamos uma queda nos anos de 2020 e 2021, seguida por um aumento em 2024, que apresenta a mediana mais alta de todo o

período analisado. Esse resultado indica que, recentemente, mais pessoas têm usufruído da gratuidade no transporte público, sugerindo um avanço nas políticas de inclusão social.

Podemos procurar entender, junto a própria SPTrans, quais são os motivos para as pessoas receberem a gratuidade, buscando entender se é por questão de renda, idade ou deficiência. Esses dados poderiam, possivelmente, serem utilizados para melhoria das políticas públicas da cidade.

2.2 Análise da Reestruturação das Linhas de Ônibus da Zona Oeste após a Inauguração da Estação Vila Sônia

2.2.1 Contexto da Inauguração

A Estação Vila Sônia, correspondente à última etapa da segunda fase da Linha 4-Amarela do Metrô de São Paulo, foi inaugurada em 17 de dezembro de 2021 como parte de complexo integrando metrô e terminal de ônibus. Embora aberta ao público nessa data, o terminal operou inicialmente em modo de operação assistida (por exemplo, com horários limitados) e só atingiu funcionamento integral no dia 10 de maio de 2022.

Após a inauguração de uma estação de metrô nova, é de se esperar que haja um replanejamento das linhas de ônibus que transportam os passageiros naquela região. Nessa seção, vamos ilustrar as mudanças que ocorreram nas linhas após a inauguração da estação, e quais os impactos sociais e econômicos dessa reestruturação.

2.2.2 Seleção das Linhas da Zona Oeste

Para obtermos as linhas que passam próximas a estação Vila Sônia, utilizaremos o atributo "Estação mais próxima" da tabela de paradas. Mesmo com esse filtro, ainda há linhas que estão na base mas não são nosso alvo de estudos, como as diversas linhas que passam pela Avenida Francisco Morato. Desse modo, vamos expandir nosso filtro para pegar apenas aquelas cujos destinos foram alterados para o terminal Vila Sônia, ou seja, as que contém Vila Sônia no nome da rota.

A partir desses filtros, podemos analisar se houve mudanças significativas nos percursos das rotas entre 2021 e 2025. Essa análise será feita, principalmente, observando a distância percorrida entre os pontos das rotas ao longo dos meses, tomando seus mínimos e máximos. Ao fazer esse cálculo, obtemos a seguinte tabela:

A partir dessa tabela, podemos notar que muitas das linhas da região tiveram seus caminhos diminuídos. As mais afetadas foram as linhas 745810 e 701310, sendo que ambas ligavam bairros até estações distantes no centro da cidade. O restante das linhas conectava algum bairro até a estação mais próxima, então é de se esperar que, caso surja uma nova estação mais próxima do bairro, o percurso da linha seja alterado até essa estação.

route_id	min_dist_km	max_dist_km	dist_km	route_long_name
745810	6.189507	17.096346	10.906839	Jd. Boa Vista - Est. Da Luz, Jd. Boa Vista - Term. Vl. Sônia
701310	5.684849	10.539948	4.855099	Pq. Arariba - Pinheiros, Pq. Arariba - Term. Vl. Sônia
807710	6.176721	9.682711	3.505991	Jd. João Xxiii - Metrô Butantã, Jd. João Xxiii - Term. Morumbi, Jd. João Xxiii - Term. Vl. Sônia
807310	3.438301	6.733491	3.295190	Jd. Guaraú - Butantã, Jd. Guaraú - Term. Morumbi, Jd. Guaraú - Term. Vl. Sônia
802310	6.945729	10.134850	3.189122	Cdhu Munck - Butantã, Cdhu Munck - Term. Morumbi, Cdhu Munck - Term. Vl. Sônia
802610	5.014927	8.091129	3.076202	Jd. Inga - Butantã, Jd. Ingá - Butantã, Jd. Ingá - Term. Vl. Sônia
802510	3.727406	6.657830	2.930424	Jd. Rosa Maria - Butantã, Jd. Rosa Maria - Term. Morumbi, Jd. Rosa Maria - Term. Vl. Sônia
801810	3.024805	4.846033	1.821228	Vl. Sônia - Butantã, Vl. Sônia - Metrô Morumbi
807521	5.787436	7.136091	1.348655	Term. Campo Limpo - Term. Morumbi, Term. Campo Limpo - Term. Vl. Sônia

Tabela 2.6: Distâncias mínimas, máximas e totais por rota. Fonte: A própria autora.

2.2.3 Histórico de passageiros nas linhas afetadas

Observem, no gráfico abaixo, o histórico de passageiros nas linhas afetadas:




Figura 2.32: Histórico de passageiros das linhas afetadas mês a mês. Fonte: A própria autora.

Quando observamos a quantidade de passageiros ao longo dos anos, notamos que todas as rotas sofreram uma queda brusca no número de passageiros no início de 2020. Essa queda coincide com o início da pandemia de COVID-19 e a quarentena em São Paulo. Além disso, após 2020, algumas linhas voltaram a crescer, mas não chegaram a ultrapassar os níveis pré-pandemia.

Os dados refletem mudanças no comportamento populacional, como home office. Ainda assim, as linhas da região contam com alto número de passageiros transportados, sendo próximas a 100 mil pessoas por mês. Vale notar que as duas linhas mais afetadas em questão de diminuição de quilometragem também são as que mais carregam passageiros na região, o que pode ter motivado a realocação do fluxo dessas rotas para um transporte mais eficiente, como o metrô.

2.2.4 As duas linhas mais afetadas: 745810 e 701310

A linha 745810

A linha 745810, que liga o bairro Jd Boa Vista ao centro, foi a mais afetada, saindo de 17km percorridos para apenas 6km. Antes, a linha ia até a Estação da Luz, no centro de São Paulo, passando por pontos importantes como Butantã, Pinheiros, Paulista e República. No gráfico abaixo, é possível observar a drástica mudança no percurso da linha.



(a) Rota da linha 745810 Jd Boa Vista - Estação da Luz em mai/2022.



(b) Rota da linha 745810 Jd Boa Vista - Term. Vila Sônia em jun/2022

Figura 2.33: Comparação entre as rotas da linha 745810. Fonte: A própria autora.

Em junho de 2022, a rota foi modificada para ir até a Estação Vila Sônia, o que obriga os passageiros a ou pagar a mais para utilizar o metrô, ou pegar outro ônibus para ir ao seu destino, o que se torna especialmente difícil no horário de pico na Raposo Tavares, por onde passam linhas que ligam bairros dormitórios ao centro. Essas linhas possuem um alto número de passageiros, conforme o boxplot abaixo, que mostra que a média de passageiros nas linhas que passam na região é de 136 mil, e a mediana de 118 mil.

Distribuição de Passageiros das rotas que passam na Raposo Tavares




Figura 2.34: Boxplot da quantidade total de passageiros nas linhas que passam pela Raposo Tavares, considerando os 10 anos de dados de passageiros. Fonte: A própria autora.




Figura 2.35: Histórico de passageiros da linha 745810, ao longo de 10 anos. Fonte: A própria autora.

Segundo o [PORTAL DO TRÂNSITO, MOBILIDADE & SUSTENTABILIDADE \(2024\)](#), os ônibus padron possuem capacidade de transportar 80 passageiros. Assumindo que todos os veículos da região seguem esse padrão, para fins de simplificação (há algumas linhas que possuem veículos articulados, mas iremos desconsiderar esses casos), seriam necessários 1875 veículos para transportar as 150 mil pessoas que utilizaram a linha 745810 em dez/24, ou seja, 1 ônibus a cada 4,61 minutos, sabendo que os veículos circulam de 4h40 à 00h00.

$$\frac{60 \text{ minutos} \times 20,6 \text{ horas} \times 7 \text{ dias}}{1875 \text{ veículos}} = 4,61 \text{ minutos/ônibus}$$

Quando olhamos apenas para os dias úteis, o número de passageiros cai para 119.725 (representando 79.8% do total), e o número de veículos cai para 1497, ou seja, 1 ônibus a cada 4,12 minutos, ainda erroneamente assumindo que todos os horários do dia possuem o mesmo fluxo.

$$\frac{60 \text{ minutos} \times 20,6 \text{ horas} \times 5 \text{ dias}}{1497 \text{ veículos}} = 4,12 \text{ minutos/ônibus}$$

Segundo os dados do GTFS de março de 2025, na linha 745810, durante os dias de semana, entre 05h e 10h, e 16h e 00h, os ônibus saem com intervalos de 30 minutos, e entre 10h e 16h, com intervalo de 20 minutos. Mesmo assumindo que a maioria dos veículos da rota sejam articulados, com o dobro da capacidade de passageiros (chegando a 160), é possível notar que há demanda em excesso para a quantidade de veículos na frequência proposta.

De acordo com o censo de 2022, do IBGE, há cerca de 117.738 pessoas que moram no distrito Raposo Tavares, por onde a linha 745810 faz todo o seu trajeto, porém, é importante notar que nos arredores do bairro Jd Boa Vista estão surgindo diversos condomínios prediais do projeto "Reserva Raposo", sendo 22 mil apartamentos planejados, que servirão de moradia para mais de 80 mil pessoas, o que deverá aumentar a demanda da região

por transporte.



Figura 2.36: Plano de construção do Reserva Raposo, um mega projeto de habitação que está sendo construído próximo a Raposo Tavares. Fonte: Reserva Raposo.

Parte da linha 745810 já foi desviada para cobrir algumas paradas próximas aos novos condomínios, porém, no patamar atual, a sobrecarga do sistema é iminente, ainda mais considerando a volta ao trabalho presencial (G1, 2025). O empreendimento prevê a construção de um terminal rodoviário para dar vazão aos moradores, projeto que poderá ser analisado futuramente, quando novos dados forem disponibilizados.

Desse modo, conseguimos analisar que a nova estação Vila Sônia impactou fortemente os habitantes da região do bairro Jd Boa Vista, que precisaram alterar seus caminhos para chegar ao centro de São Paulo. Apesar de mais rápido e confortável, o metrô cobra uma passagem adicional pelo uso, sem integração tarifária completa com os ônibus da região, o que pode representar um alto impacto no orçamento das famílias, especialmente as de baixa renda. Ao considerarmos que o mega projeto Reserva Raposo é destinado a habitação social, o número de pessoas impactadas fica ainda maior. Esse cenário aponta para a necessidade urgente de revisão da política tarifária da integração ônibus-metrô nas estações inauguradas recentemente, a exemplo do modelo implementado entre os usuários dos ônibus operados pela SPTrans, que podem fazer integração gratuita em uma janela específica ao pagar com o bilhete único.

Além da questão tarifária, os dados do GTFS indicam que a frequência atual das linhas da região é insatisfatória diante da demanda observada, o que já causa superlotação, problema que tende a se agravar de forma crítica com o projeto Reserva Raposo. Diante disso, recomenda-se que a SPTrans e a Secretaria Municipal de Mobilidade e Transportes adotem a revisão imediata da frequência das linhas 745810 com base nos dados reais de demanda aqui apresentados e a elaboração de um plano de expansão do sistema de transporte para a região, com aprovação em consulta pública com a população da região.


A linha 701310

Podemos replicar a mesma análise feita com a linha 745810 para a 701310. A linha 701310 foi a segunda mais afetada pela nova estação, tendo o seu percurso cortado pela

metade, alterado de Pinheiros para Vila Sônia. De metrô, esse percurso leva por volta de 15 minutos, porém, novamente, um dos grandes problemas com a reestruturação é o fato do passageiro ter que pagar a mais para trocar de meio de transporte: ou ele paga a mais, ou dificulta seu trajeto pegando um segundo ônibus, o que pode ser difícil em horário de pico. Esse é mais um cenário que reforça a necessidade da revisão da política de integração entre os transportes da cidade.


A linha 701310 passa pela Estrada do Campo Limpo e Francisco Morato, duas vias importantes para a região. Ao considerarmos todas as linhas que passam pelas duas vias, obtemos os seguintes boxplots:

Distribuição de Passageiros das rotas que passam na Francisco Morato



(a) Boxplot da quantidade de passageiros nas linhas da Francisco Morato ao longo de 10 anos

Distribuição de Passageiros das rotas que passam na Estrada do Campo Limpo



(b) Boxplot da quantidade de passageiros nas linhas da Estrada do Campo Limpo ao longo de 10 anos

Figura 2.37: Comparação entre os boxplots da quantidade de passageiros nas principais vias da linha 701310. Fonte: A própria autora.

Nesses gráficos, é possível notar que a quantidade de passageiros nos ônibus das duas regiões é tão alta quanto as da Raposo Tavares. Vale notar que, nesses dados, temos

máximos muito maiores do que no boxplot da Raposo Tavares. Temos aqui, então, o mesmo problema de transferência entre ônibus

Observe, no gráfico abaixo, que a quantidade de passageiros da linha 701310 fica próxima de 100 mil pessoas, após a pandemia. Se considerarmos os dados de passageiros de dezembro de 2024, maior pico dos últimos meses, temos que, para transportar 148,71 mil passageiros no mês, seriam necessários um ônibus padron a cada 4,61 minutos, ou um ônibus articulado a cada, aproximadamente, 9 minutos, diferindo muito do horário atual da linha que, entre 06h-07h e 07h-08h, tem uma frequência de 1 ônibus a cada 30 minutos. Vale notar que, para esse cálculo, consideramos que a linha opera por 20,6 horas, mas na verdade, ela também opera entre 00h e 2h da manhã, tendo um horário de operação total de 21,63 horas. Optamos por desconsiderar esse período adicional na operação, dado que a quantidade de passageiros nas linhas noturnas exclusivamente noturnas não é alta.




Figura 2.38: Histórico de passageiros da linha 701310, ao longo de 10 anos. Fonte: A própria autora.

Outras considerações

As linhas Jd João XXIII, Jd Guaraú, CDHU Munck, Jd Ingá e Jd Rosa Maria também foram afetadas, porém em um grau menor do que as outras duas: seus percursos foram redirecionados do Butantã para a estação Morumbi e, posteriormente, para a Vila Sônia. Apesar de parecer ter menos impacto, essa mudança afetaria com muito mais peso, por exemplo, estudantes da USP Butantã que moram nesses bairros e foram forçados a ou fazer um trajeto mais difícil e demorado, pegando um segundo ônibus, ou pagando a mais pelo metrô.

2.3 Painel interativo - Analise qualquer rota da cidade da SPTrans

Vendo como pode ser importante analisar uma rota específica detalhadamente, desenvolvemos um dashboard interativo para explorar informações históricas e operacionais das rotas de transporte público de São Paulo. O painel centraliza diferentes bases, incluindo

dados de passageiros, frequências, distâncias percorridas e um mapa com o trajeto, para cada linha de ônibus.

O usuário pode selecionar uma rota específica em um menu suspenso, que atualiza automaticamente todas as visualizações e tabelas exibidas, permitindo ao usuário analisar e comparar o comportamento e a evolução de cada linha, observando métricas como volume de passageiros, distância total da rota, distância realmente percorrida e frequência programada ao longo dos anos.




Figura 2.39: Captura de tela do dashboard interativo, com a rota 808210 selecionada no filtro, ilustrando a seção resumo dos principais dados da rota, o histórico mais recente da rota e a série temporal da quantidade de passageiros. Fonte: A própria autora.




Figura 2.40: Captura de tela do dashboard interativo, com a rota 808210 selecionada no filtro, ilustrando a seção de histórico da rota, frequência ideal calculada e distância percorrida. Fonte: A própria autora.

O dashboard foi desenvolvido para que os cidadãos possam observar a rota que mais utilizam de forma mais detalhada, e obter dados que auxiliem seus pedidos de melhoria.

Por exemplo, ao analisarmos que a frequência ideal de uma rota é muito menor do que a frequência atual, podemos pedir o aumento da frequência para as autoridades competentes, utilizando-se de dados que mostrem a quantidade real de passageiros que se utilizam da rota.

O dashboard está disponível no repositório do trabalho, e pode ser executado através do arquivo `app_rotas.py`.

2.4 Resumo dos principais resultados e suas interpretações

Resultado	Implicações
Reestruturação do sistema de transporte O número de paradas cresceu continuamente, enquanto o de rotas diminuiu até 2020 e só então voltou a crescer. Zonas Sul e Leste concentram o maior número total de paradas e rotas. Zonas Oeste e Centro se destacam na criação de novas rotas, sem aumento proporcional de paradas.	A rede expandiu sua cobertura física e passou por forte reestruturação durante a pandemia. A oferta reflete a extensão territorial e a alta demanda populacional dessas regiões. O planejamento tem sido mais intenso nessas áreas, priorizando reestruturação e eficiência. Considerando que há migração de empregos para outras zonas da cidade, as zonas com prioridade no planejamento podem ser revisadas.
Correlação com a População Correlação positiva forte entre número de paradas e população afetada.	A expansão das paradas tem sido eficiente, priorizando áreas mais populosas.
Análise de Centralidade da Rede As métricas de centralidade (betweenness e closeness) caíram após 2018. Correlação negativa entre centralidade e número de paradas.	A rede tornou-se menos centralizada e mais distribuída, reduzindo a dependência de poucos nós. Com mais paradas, cada ponto torna-se menos crítico para o funcionamento geral.
Características e Rankings das Rotas Rotas com mais passageiros (ex: Itaquera, Jd. Ângela) ligam bairros periféricos a áreas centrais. Itaquera tem muitas paradas e poucas linhas longas (média de 27,5 km). Jardim Ângela lidera em número de rotas e paradas próximas, com alta demanda.	Evidencia o papel essencial dessas linhas na conexão entre periferias e polos de emprego. O bairro possui rotas extensas e sobrecarregadas; um replanejamento poderia reduzir tempos e melhorar o serviço. A futura estação de metrô deve reduzir significativamente o tempo de viagem e aliviar a rede.

continua →

Tabela 2.7: Quadro de principais achados e implicações da pesquisa.

Principal resultado	Implicações
Perfil e Volume de Passageiros	
Houve queda abrupta em 2020 (pandemia); a recuperação é parcial.	A pandemia alterou padrões de mobilidade e comportamento (ex: home office).
Pagamento em dinheiro vem diminuindo.	Indica maior adesão ao Bilhete Único e à digitalização dos pagamentos.
Aumentou o número de passageiros com gratuidade em 2024.	Reflete expansão de políticas de inclusão social e maior acesso ao transporte.
Reestruturação da Zona Oeste (Estação Vila Sônia)	
A inauguração da Estação Vila Sônia (2022) levou à reestruturação de linhas que iam ao centro.	O sistema migrou para modelo integrativo (ônibus + metrô), reduzindo tempo, mas elevando custos.
O encurtamento de linhas obriga nova tarifa ou baldeações.	Gerou impacto financeiro e de tempo para os passageiros, especialmente nas linhas mais cheias, o que reforça a necessidade de revisão da política de integração entre os transportes.
A linha 745810 (Jd. Boa Vista) transporta 150 mil passageiros/mês, com frequência insuficiente.	A oferta é criticamente menor que a demanda; há risco de colapso com o crescimento regional. Há necessidade urgente de revisão da frequência da linha.
Ferramenta de Análise (Dashboard)	
Foi desenvolvido um painel interativo para consulta pública.	Promove transparência e empodera cidadãos a demandar melhorias baseadas em dados.

Tabela 2.7: *Quadro de principais achados e implicações da pesquisa. Fonte: A própria autora.*

Capítulo 3

Conclusões

Este trabalho teve como objetivo realizar uma modelagem matemática da rede de transporte público por ônibus de São Paulo, operada pela SPTrans, buscando analisar a eficiência da malha e identificar pontos de melhoria. A análise abrangeu um período temporal estratégico, de 10 anos, contemplando os impactos da pandemia de Covid-19 na demanda, e procurou preencher as lacunas de estudos anteriores ao focar na integração de múltiplas fontes de dados e na estrutura geoespacial detalhada do sistema.

A metodologia empregada, centrada na teoria dos grafos e no uso de ferramentas computacionais para ingestão, tratamento e visualização dos dados, provou-se útil para o tratamento, padronização e unificação de um volume alto de dados. Obtivemos sucesso na integração dos dados estruturais do GTFS e das séries temporais de passageiros transportados. Conseguimos também juntar dados demográficos complementares do Censo do IBGE de 2022, enfrentando, porém, dificuldades computacionais para integrar totalmente os dados do censo com as informações geográficas do GTFS. Ainda assim, enfrentamos alguns desafios de inconsistências e dados faltantes, frequentemente encontrados em fontes públicas, ao solicitar o histórico completo à SPTrans, e conseguimos, com sucesso, documentar algumas inconsistências que ainda restaram nos dados que estudamos.

Alcançamos os objetivos propostos com a criação do grafo da rede municipal, que viabilizou análises de centralidade e nos permitiu observar a melhoria que ocorreu no sistema de transporte ao longo do tempo. Também conseguimos analisar rotas com alto volume de passageiros, e elaborar uma análise temporal das principais estatísticas das bases obtidas, na qual observamos mudanças significativas na estrutura do sistema de transporte paulista e da demanda dos usuários. Adicionalmente, o estudo de caso sobre a reestruturação das linhas da Zona Oeste, originado da inauguração da Estação Vila Sônia, demonstrou a importância dos dados para avaliar os impactos das modificações na infraestrutura urbana, fornecendo argumentos para possíveis novos estudos e políticas.

Ao avaliar a eficiência da rede de transporte público de São Paulo, entendida neste trabalho como a capacidade de equilibrar oferta e demanda, sem priorizar o lucro das operadoras de transporte, é possível perceber um cenário de contrastes: de um lado, há avanços importantes, como o aumento do uso do Bilhete Único, a ampliação das gratuidades e a descentralização do sistema, que mostram um progresso tecnológico, social

e estrutural. Porém, ao analisarmos casos como a reestruturação das linhas na Zona Oeste, depois da abertura da Estação Vila Sônia, conseguimos identificar um aumento de custos do transporte para o usuário final, além da observação de desequilíbrio entre oferta e demanda, como na linha 745810 (Jd. Boa Vista), onde a quantidade de viagens é claramente insuficiente. Além disso, identificamos no Jardim Ângela e em Itaquera dois exemplos de regiões que necessitam de mais planejamento e foco em políticas públicas, de forma a melhorar a qualidade do transporte. Essas situações mostram a necessidade de revisar o planejamento e as políticas, para garantir um serviço mais equilibrado e eficiente para toda a cidade, que melhore a qualidade de vida dos moradores de São Paulo, sempre se amparando em dados, como os discutidos neste trabalho.

A principal contribuição prática desta pesquisa é a elaboração de uma base de dados confiável, que viabiliza análises mais aprofundadas do sistema, permitindo, por exemplo, a criação de um painel interativo, que fornece ao cidadão uma visão mais aprofundada de um dos tópicos que mais impacta o seu dia a dia: o transporte.

Esse painel centraliza as bases de dados tratadas e as análises realizadas, permitindo que servidores públicos e cidadãos explorem visualmente informações operacionais de qualquer linha, como trajeto, frequência programada e histórico de demanda de passageiros. O painel fornece transparência e subsídio técnico, possibilitando a população fundamentação técnica para solicitações de melhoria no sistema de transporte.

Desse modo, essa monografia avança na compreensão da mobilidade urbana paulistana ao fornecer não apenas uma análise estrutural e temporal da rede de ônibus, mas também uma base de dados e plataforma dinâmica para o planejamento e aperfeiçoamento contínuo do transporte público, visando um sistema mais eficiente e condizente com as necessidades da população.

Referências

- [ABDELAZIZ *et al.* 2024] Abdullah I. ABDELAZIZ, Kent A. HANSON, Charles E. GABER e Todd A. LEE. “Optimizing large real-world data analysis with parquet files in r: a step-by-step tutorial”. *Pharmacoepidemiology and Drug Safety* 33.3 (2024), e5728. DOI: <https://doi.org/10.1002/pds.5728>. eprint: <https://onlinelibrary.wiley.com/doi/pdf/10.1002/pds.5728>. URL: <https://onlinelibrary.wiley.com/doi/abs/10.1002/pds.5728> (citado na pg. 7).
- [AGÊNCIA MURAL 2025] AGÊNCIA MURAL. *Entre atrasos nas obras, moradores do Jardim Ângela revelam expectativas com o Metrô*. <https://agenciamural.org.br/entre-atrasos-nas-obras-moradores-do-jardim-angela-revelam-expectativas-com-o-metro/#:~:text=Em%20março%20de%202025%2C%20o,esta%20seja%20concluída%20em%202028..> Acesso em: 18 outubro 2025. 2025 (citado na pg. 30).
- [BARTHÉLEMY 2011] Marc BARTHÉLEMY. “Spatial networks”. *Physics Reports* 499.1-3 (2011), pp. 1–101 (citado na pg. 20).
- [CHRISTIE ASCHWANDEN 2015] CHRISTIE ASCHWANDEN. *Not Even Scientists Can Easily Explain P-values*. <https://fivethirtyeight.com/features/not-even-scientists-can-easily-explain-p-values>. Acesso em: 01 novembro 2025. 2015 (citado na pg. 21).
- [FREEMAN 1978] Linton C. FREEMAN. “Centrality in social networks conceptual clarification”. *Social Networks* 1.3 (1978), pp. 215–239. ISSN: 0378-8733. DOI: [https://doi.org/10.1016/0378-8733\(78\)90021-7](https://doi.org/10.1016/0378-8733(78)90021-7). URL: <https://www.sciencedirect.com/science/article/pii/0378873378900217> (citado na pg. 19).
- [G1 2014] G1. *Maior linha de ônibus de SP tem 102 km e leva 4h40 para completar trajeto*. <https://g1.globo.com/sao-paulo/noticia/2014/08/maior-linha-de-onibus-de-sp-tem-102-km-e-leva-4h40-para-completar-trajeto.html>. Acesso em: 19 outubro 2025. 2014 (citado na pg. 44).
- [G1 2025] G1. *Home office vai acabar? Por que cada vez mais empresas estão voltando ao trabalho presencial*. <https://g1.globo.com/trabalho-e-carreira/noticia/2025/02/26/home-office-vai-acabar-por-que-cada-vez-mais-empresas-estao-voltando-ao-trabalho-presencial.ghtml>. Acesso em: 3 agosto 2025. 2025 (citado na pg. 54).

- [GEOPANDAS 2024] GEOPANDAS. *Geopandas sjoin*. <https://github.com/geopandas/geopandas/blob/main/geopandas/tools/sjoin.py>. Acesso em: 01 novembro 2025. 2024 (citado na pg. 9).
- [GTFS ORG s.d.] GTFS ORG. *About the GTFS*. <https://gtfs.org/about>. Acesso em: 01 novembro 2025 (citado na pg. 5).
- [METRÔCPTM 2024] METRÔCPTM. *Veja como será a Estação Jardim Ângela da Linha 5-Lilás*. <https://www.metrocptm.com.br/veja-como-sera-a-estacao-jardim-angela-da-linha-5-lilas>. Acesso em: 18 outubro 2025. 2024 (citado na pg. 30).
- [MORETTIN e SINGER 2019] Pedro Alberto MORETTIN e Julio da Motta SINGER. *Introdução à Ciência de Dados: fundamentos e aplicações*. Available at: <https://www.ime.usp.br/~jmsinger/MAE5755/cdados2019ago06.pdf>. São Paulo: Departamento de Estatística da USP, 2019. URL: <https://www.ime.usp.br/~jmsinger/MAE5755/cdados2019ago06.pdf> (citado na pg. 21).
- [PORTAL DO TRÂNSITO, MOBILIDADE & SUSTENTABILIDADE 2024] PORTAL DO TRÂNSITO, MOBILIDADE & SUSTENTABILIDADE. *Qual é o limite de passageiros em ônibus urbanos?* <https://www.portaldotransito.com.br/noticias/mobilidade-e-tecnologia/transporte-coletivo/qual-e-o-limite-de-passageiros-em-onibus-urbanos/>. Acesso em: 3 agosto 2025. 2024 (citado na pg. 53).
- [PREFEITURA DO MUNICÍPIO DE SÃO PAULO 2008] PREFEITURA DO MUNICÍPIO DE SÃO PAULO. *Regiões, Subprefeituras e Distritos Municipais*. https://www.prefeitura.sp.gov.br/cidade/secretarias/subprefeituras/upload/pinheiros/11_regioes.pdf. Acesso em: 1 jun. 2025. 2008 (citado na pg. 10).
- [PREFEITURA DO MUNICÍPIO DE SÃO PAULO 2025] PREFEITURA DO MUNICÍPIO DE SÃO PAULO. *GeoSampa Metadados*. Acesso em: 21 jun. 2025. 2025. URL: https://metadados.geosampa.prefeitura.sp.gov.br/geonetwork/srv/por/catalog.search?sessionId=D7C42FF7016A0E122DF0051F33224C41#/search?facet.q=topicCat%2Ftransportation&resultType=manager&sortBy=relevance&fast=index&_content_type=json&from=1&to=50 (citado na pg. 10).
- [REDE NOSSA SÃO PAULO 2024] REDE NOSSA SÃO PAULO. *Tempo de deslocamento por transporte público aumenta em São Paulo e chega a 2h47 por dia*. <https://www.nossasaopaulo.org.br/2024/09/19/tempo-de-deslocamento-por-transporte-publico-aumenta-em-sao-paulo-e-chega-a-2h47-por-dia/>. Acesso em: 10 maio 2025. 2024 (citado na pg. 1).
- [RODRIGUE 2020] Jean-Paul RODRIGUE. *The Geography of Transport Systems*. 4ª ed. New York: Routledge, 2020. ISBN: 9780367364632 (citado na pg. 20).

REFERÊNCIAS

- [SCHWARTZMAN 1975] Simon SCHWARTZMAN. *Da Responsabilidade Pública dos Governantes: Paradoxos e Perspectivas*. Versão revista do trabalho apresentado ao Seminário sobre Políticas Públicas realizado pela Escola Brasileira de Administração Pública da Fundação Getúlio Vargas no Rio de Janeiro, maio de 1975. A responsabilidade pelos conceitos emitidos é do autor. Publicado em Dados 12, 1976, pp. 5 a 21. 1975. URL: <https://www.schwartzman.org.br/simon/respons.htm> (acesso em 29/06/2025) (citado na pg. 3).
- [SILVA 2018] Danilo SILVA. “Modelagem do transporte urbano através de grafos” (set. de 2018) (citado nas pgs. 2, 18).
- [SOUSA 2016] Sandro SOUSA. “Estudo das propriedades e robustez da rede de transporte público de são paulo” (ago. de 2016). DOI: [10.13140/RG.2.1.3681.4320/2](https://doi.org/10.13140/RG.2.1.3681.4320/2) (citado na pg. 1).
- [SPTRANS - SÃO PAULO TRANSPORTE S.A. 2024] SPTRANS - SÃO PAULO TRANSPORTE S.A. *Relatório Integrado da Administração 2024*. <https://www.sptrans.com.br/relatorio-integrado-da-administracao-2024/>. Acesso em: 10 maio 2025. 2024 (citado na pg. 1).
- [SUGUIY *et al.* 2020] Takao SUGUIY, Marcius FABIUS HENRIQUES DE CARVALHO e Paulo AUGUSTO VALENTE FERREIRA. “Efficiency versus satisfaction in public transport: practices in brazilian cities”. *Case Studies on Transport Policy* 8.3 (2020), pp. 938–945. ISSN: 2213-624X. DOI: <https://doi.org/10.1016/j.cstp.2020.05.003>. URL: <https://www.sciencedirect.com/science/article/pii/S2213624X17303231> (citado na pg. 2).
- [TUKEY 1977] John W TUKEY. “Exploratory data analysis”. *Reading/Addison-Wesley* (1977) (citado na pg. 21).
- [YAI 2016] André YAI. “Análise e visualização de dados do transporte público de ônibus da cidade de são paulo” (jan. de 2016) (citado na pg. 1).